

INDICE

ABSTRACT	3
INTRODUCCIÓN	5
BACKGROUND	10
CIRUGÍA CARDIACA	10
BREVE RESEÑA HISTÓRICA	10
CONCEPTO DE CIRCULACIÓN EXTRACORPÓREA	12
IMPORTANCIA DEL TIEMPO DE BOMBA DE CIRCULACIÓN EXTRACORPÓREA	15
FACTORES QUE AFECTAN EL TIEMPO DE BOMBA	16
MATERIALES Y MÉTODOS	20
DESCRIPCIÓN DEL DISEÑO DEL ESTUDIO	21
RECOLECCIÓN DE DATOS	21
VARIABLES/FEATURES ANALIZADAS	21
BREVE DESCRIPCIÓN DE LAS CATEGORÍAS DE LA VARIABLE CIRUGÍA	23
CREACIÓN VARIABLE ("DIFF")	24
ANÁLISIS EXPLORATORIO DE DATOS	24
DIVISIÓN DE LA MUESTRA	26
MODELO DE CLASIFICACIÓN (PREOPERATORIO)	27
Entrenamiento del modelo	27
Validación del Modelo	27
Modelo de Predicción (Intraoperatorio)	29
Entrenamiento del modelo	29
Validación del Modelo	29
HERRAMIENTAS	30
RESULTADOS	31
ANÁLISIS UNIVARIADO	31
PREOPERATORIO	35
ANÁLISIS BIVARIADO (PREOPERATORIO)	35
ANÁLISIS BIVARIADO (INTRAOPREOPERATORIO)	42
PREOPERATORIO	49
RED NEURONAL	49
Entrenamiento del modelo	49
Rendimiento del modelo	50
Área bajo la curva (AUC)	51
SUPPORT VECTOR MACHINE (SVM)	55
Entrenamiento del modelo	55
Rendimiento del modelo	56

Área bajo la curva (AUC)	57
INTRAOPERATORIO	58
RED NEURONAL	58
Entrenamiento del modelo	59
Rendimiento del modelo	59
SUPPORT VECTOR MACHINE (SVM)	61
Entrenamiento del modelo	61
Rendimiento del modelo	62
RN (SIN OUTLIERS)	64
Entrenamiento del modelo	64
Rendimiento del modelo	65
SVM (SIN OUTLIERS)	65
Entrenamiento del modelo	65
Rendimiento del modelo	66
PREDICCIÓN DE UN CASO	67
DISCUSIÓN	70
CONCLUSIÓN	72
TRABAJO FUTURO	73
REFERENCIAS	74

ABSTRACT

Introducción

La cirugía cardíaca con circulación extracorpórea (CEC) es esencial para tratar diversas afecciones cardiovasculares, pero también presenta desafíos hemodinámicos significativos. Un problema crucial es identificar a los pacientes que podrían beneficiarse del uso intraoperatorio del balón de contrapulsación intraaórtica (BCIAO), un dispositivo que mejora la perfusión coronaria y alivia la carga del corazón. Además de predecir dificultades intraoperatorias en la salida de CEC son claves para optimizar los resultados. Los métodos actuales de predicción, como los puntajes de riesgo global (EUROSCORE y STS), no permiten anticipar de manera efectiva esta necesidad específica durante la cirugía.

Objetivo

Desarrollar modelos de aprendizaje automático—Máquinas de Vectores de Soporte (SVM) y Redes Neuronales (RN)—para clasificar la necesidad de BCIAO en el preoperatorio y predecir la dificultad intraoperatoria en la salida de CEC, medida por DIFF (diferencia entre los tiempos de CEC y clampeo).

Métodos

Se realizó un análisis retrospectivo de 1,210 registros de pacientes sometidos a cirugía cardíaca con CEC entre 2018 y 2023. La muestra se dividió en conjuntos de entrenamiento y testeo (70/30). Utilizando técnicas de machine learning y validación cruzada, se construyó un modelo de RN y SVM en el preoperatorio para clasificar a los pacientes según la necesidad de BCIAO y en el intraoperatorio para predecir la variable DIFF en función de las mismas variables demográficas y clínicas. Evaluándose el rendimiento del modelo mediante métricas como exactitud, sensibilidad y especificidad en el preoperatorio y R^2 , RMSE y MAE en el intraoperatorio.

Resultados

En la clasificación preoperatoria de BCIAO, RN mostró un mejor desempeño que SVM, con mayor Accuracy (0.8415 vs. 0.8252) y Kappa (0.6829 vs. 0.6504). Ambos tuvieron igual Sensibilidad (0.8618), pero RN destacó en PPV (0.8281 vs. 0.8030). Estos resultados sugieren que RN es ligeramente superior.

En la predicción intraoperatoria de DIFF, el modelo SVM es superior al modelo de Redes Neuronales (RN) en todas las métricas evaluadas. Presenta un mayor R^2 (0.5917 vs. 0.2438), así como menores errores RMSE (9.7782 vs. 13.3165) y MAE (6.9633 vs. 10.5244), indicando mejor ajuste y precisión en la predicción.

Conclusión:

Este estudio demuestra la utilidad de combinar SVM y RN para la toma de decisiones preoperatorias e intraoperatorias en cirugía cardíaca. Los modelos de RN clasificaron eficazmente la necesidad de BCIAO y el modelo de SVM predijo moderadamente los desafíos en la salida de CEC, ofreciendo importantes implicancias clínicas. proporcionando una herramienta complementaria para la planificación quirúrgica personalizada. Su aplicación podría mejorar los resultados postoperatorios y optimizar el uso de recursos durante cirugías de alto riesgo.

Introduction

Cardiac surgery with cardiopulmonary bypass (CPB) is essential for treating various cardiovascular conditions, but it also poses significant hemodynamic challenges. A crucial issue is identifying patients who could benefit from the intraoperative use of the intra-aortic balloon pump (IABP), a device that enhances coronary perfusion and reduces cardiac workload. Additionally, predicting intraoperative difficulties during CPB weaning is key to optimizing outcomes. Current prediction methods, such as global risk scores (EUROSCORE and STS), do not effectively anticipate this specific need during surgery.

Objective

To develop machine learning models—Support Vector Machines (SVM) and Neural Networks (NN)—to classify the need for IABP in the preoperative period and predict intraoperative difficulty during CPB weaning, measured by DIFF (the difference between CPB and aortic cross-clamp times).

Methods

A retrospective analysis of 1,210 cardiac surgery patient records with CPB from 2018 to 2023 was conducted. The sample was split into training and testing sets (70/30). Using machine learning techniques and cross-validation, NN and SVM models were developed for preoperative IABP classification and intraoperative DIFF prediction based on the same demographic and clinical variables. Model performance was assessed using accuracy, sensitivity, and specificity for classification and R^2 , RMSE, and MAE for prediction.

Results

In preoperative IABP classification, NN outperformed SVM, showing higher accuracy (0.8415 vs. 0.8252) and Kappa (0.6829 vs. 0.6504). Both models had equal sensitivity (0.8618), but NN excelled in PPV (0.8281 vs. 0.8030), suggesting that NN is slightly superior.

In intraoperative DIFF prediction, the SVM model outperformed NN in all metrics, achieving higher R^2 (0.5917 vs. 0.2438) and lower errors (RMSE: 9.7782 vs. 13.3165; MAE: 6.9633 vs. 10.5244), indicating better fit and accuracy.

Conclusion

This study highlights the utility of combining SVM and NN for preoperative and intraoperative decision-making in cardiac surgery. NN effectively classified IABP needs, while SVM more accurately predicted CPB weaning difficulties. Their application could enhance postoperative outcomes and optimize resource use in high-risk surgeries.

INTRODUCCIÓN

La cirugía cardíaca con circulación extracorpórea (CEC) ha revolucionado el tratamiento de enfermedades cardiovasculares, permitiendo procedimientos complejos que salvan vidas. Sin embargo, a lo largo de la historia, se ha evidenciado que la CEC no está exenta de desafíos y complicaciones potenciales para los pacientes. Uno de los aspectos cruciales en la planificación de una cirugía cardíaca con CEC es la identificación de aquellos pacientes que pueden requerir medidas adicionales de soporte hemodinámico, como el uso de un balón de contrapulsación intraaórtico (BCIA), para garantizar una recuperación segura y efectiva.

La historia de la bomba de circulación extracorpórea se entrelaza con los avances en la cirugía cardíaca y la búsqueda constante de optimizar los resultados quirúrgicos. Desde los primeros intentos de reemplazar las funciones cardíacas mediante dispositivos mecánicos en la década de 1920, hasta la exitosa implementación de la CEC en la década de 1950 (John H. Gibbon Jr. En 1953), la tecnología y las técnicas han evolucionado de manera significativa. La introducción de la CEC permitió procedimientos más complejos al brindar un método confiable para mantener la circulación sistémica durante la cirugía cardíaca, lo que abrió las puertas a la corrección de defectos cardíacos y la revascularización coronaria.

Sin embargo, esta maravillosa herramienta no está exenta de limitaciones. Durante la CEC, los pacientes pueden experimentar una respuesta inflamatoria sistémica y desequilibrios hemodinámicos que pueden tener implicaciones clínicas significativas. La necesidad de proporcionar un soporte circulatorio adicional, como el balón de contrapulsación intraaórtico (BCIAO), es una consideración crítica en la gestión de estos pacientes. El BCIAO es un dispositivo que se coloca por la arteria femoral, se progresa hasta la arteria aorta y se sincroniza con el ciclo cardíaco para mejorar la perfusión coronaria y disminuir la carga de trabajo del corazón, especialmente en situaciones de compromiso hemodinámico.

En este contexto, surge la necesidad de desarrollar un enfoque de clasificación preoperatoria que permita identificar de manera temprana a los pacientes que podrían beneficiarse del uso del BCIAO durante la cirugía cardíaca con CEC. Esta clasificación podría basarse en una combinación de factores clínicos, ecográficos, como la fracción de eyección del ventrículo izquierdo (FEY), anatomía cardiovascular, tipo de cirugía, sexo, edad, etc. que puedan prever la vulnerabilidad del paciente a desafíos hemodinámicos durante el procedimiento. Un enfoque personalizado y predictivo que permita una toma de decisiones más informada por parte del equipo médico, optimizando la planificación preoperatoria y mejorando los resultados postoperatorios.

En este trabajo se analizó la historia de la CEC y el desarrollo del BCIA, así como los avances actuales en la identificación de factores predictivos. El objetivo es contribuir al conocimiento en este campo y proporcionar una base para el desarrollo de enfoques más personalizados y efectivos en la gestión de pacientes sometidos a cirugía cardíaca con CEC.

Esta investigación se lleva a cabo para abordar la necesidad crítica de respaldar la toma de decisiones en cirugías cardíacas que requieren el uso de bomba de circulación extracorpórea (BCEC). Se enmarca en el contexto de otras investigaciones en el campo de la cirugía cardíaca con BCEC, las cuales han aportado conocimientos sobre las alteraciones fisiopatológicas de la circulación extracorpórea. No obstante, el presente trabajo se enfoca en la toma de decisiones preoperatorias e intraoperatorias, subrayando la necesidad de soporte circulatorio, un aspecto que hasta el momento no ha sido abordado en otras investigaciones

En relación con otros autores, esta investigación busca llenar varios blancos identificados en estudios previos:

Limitaciones de los Puntajes de Riesgo Globales: A diferencia de los puntajes de riesgo globales convencionales, este estudio se centra en desarrollar un modelo de clasificación específico para el periodo preoperatorio de las cirugías cardíacas con CEC. Esto aborda la limitación de los puntajes globales al proporcionar predicciones más detalladas y precisas para respaldar decisiones en la cirugía.

Necesidad de Decisiones Personalizadas: La investigación reconoce la importancia de la toma de decisiones personalizadas en cirugías cardíacas. Busca llenar el vacío al identificar datos esenciales y utilizar técnicas de aprendizaje automático para proporcionar recomendaciones más precisas y específicas que ayuden a los cirujanos a adaptar sus enfoques quirúrgicos en función de las características únicas de cada paciente.

Potencial Impacto en la Mejora de Resultados: Al desarrollar un modelo de clasificación efectivo y específico, este estudio aspira a mejorar los resultados y la seguridad del paciente durante las cirugías cardíacas. Esto representa una contribución significativa al campo al proporcionar una herramienta práctica para los profesionales de la salud que puede resultar en mejores resultados clínicos.

Aprovechamiento de la Tecnología de Aprendizaje Automático: Esta investigación utiliza técnicas de aprendizaje automático para abordar desafíos médicos complejos, lo que amplía la frontera de cómo se pueden aplicar estas tecnologías en el contexto de la cirugía cardíaca. Esto contribuye al conocimiento existente al demostrar el potencial de estas técnicas incluso en situaciones de datos limitados.

En resumen, este estudio aporta nuevos conocimientos al campo al proporcionar un modelo de clasificación específico que aborda las limitaciones de los puntajes de riesgo globales, respalda la toma de decisiones personalizadas y tiene el potencial de mejorar los resultados en cirugías cardíacas con BCEC. Su enfoque en el periodo preoperatorio y la aplicación de tecnologías de aprendizaje automático representan contribuciones originales que avanza en la comprensión y la práctica en este ámbito crítico de la medicina.

Alcance del Trabajo:

El alcance principal de este trabajo se centra en la identificación de datos esenciales que puedan contribuir a la clasificación adecuada de pacientes sometidos a cirugía cardíaca con el uso de una bomba de circulación extracorpórea (BCEC). Se analizaron y seleccionaron las variables clínico-quirúrgicas y de exámenes complementarios que tienen un alto poder predictivo en la toma de decisiones médicas durante el procedimiento.

Se desarrolló un modelo de clasificación utilizando técnicas de machine learning con el conjunto de datos disponible, que consta de 1210 registros. El objetivo es crear un clasificador que pueda ayudar a los cirujanos a tomar decisiones informadas previo a la cirugía, como la elección de utilizar un balón de contrapulsación o ajustar la técnica quirúrgica en función de la situación clínica del paciente.

Con los datos que se dispone se generó una nueva variable= DIFF (tiempo de bomba - tiempo de clampeo) que podría corresponder a un indicador del status cardíaco del paciente, representando la dificultad en la salida de bomba y siendo un factor determinante en el tiempo total de circulación extracorpórea. Con esta variable, también usando técnicas de ML, se construyó un modelo para predecir cual será el valor de DIFF, lo que puede ser útil para la colocación precoz de BCIAO o la toma de decisiones intraoperatorias tendientes a disminuir los tiempos de clampeo o de bomba.

Aunque algunos autores como Murphy, G. J. sostienen que ..."es en gran medida imposible, al revisar estos datos, separar los efectos del paro cardiopléjico y del clampeo aórtico de los de la CPB. La contribución de la isquemia/reperfusión del miocardio a la respuesta inflamatoria sistémica y a la disfunción de órganos más amplia es desconocida y requiere una mayor evaluación en ensayos clínicos"...

Se tomaron como variables a analizar edad, sexo, tipo de cirugía, cantidad de Bypass, tiempo de bomba, tiempo de clampeo, válvula, posición de la válvula, grado de hipotermia y FEY (fracción de eyección del ventrículo izquierdo) como medida de la funcionalidad cardíaca del paciente previo al acto quirúrgico.

Se llevó a cabo una evaluación exhaustiva del modelo utilizando técnicas de validación cruzada y métricas de rendimiento pertinentes buscando alcanzar un alto nivel de precisión y sensibilidad en la clasificación de pacientes.

Limitaciones:

Tamaño Limitado del Conjunto de Datos: La principal limitación de este proyecto es el tamaño limitado de la base de datos, que consta de solo 1210 registros. Esto puede afectar la capacidad del modelo para generalizar a nuevas situaciones clínicas. Se deben implementar estrategias de mitigación del sobreajuste y la incertidumbre.

Disponibilidad de Datos Incompletos: No se tienen otras variables, que, si están presentes en los scores de relevancia utilizados clásicamente en este tipo de cirugías, como datos de laboratorio, patologías preexistentes, etc. que podrían influir en la

función cardíaca del paciente sometido a este tipo de cirugías, lo cual podría ser una limitación al estudio.

Limitaciones en la Generalización: Debido a la especificidad del problema y la falta de datos específicos sobre el intraoperatorio, el modelo puede tener dificultades para generalizar completamente a diferentes entornos clínicos o procedimientos quirúrgicos.

Validación Clínica Requerida: Aunque se desarrolló un modelo de clasificación, cualquier decisión médica basada en las predicciones del modelo debe ser validada clínicamente por profesionales de la salud antes de su implementación en situaciones reales.

Cambios en la Práctica Médica: Las decisiones médicas y las técnicas quirúrgicas pueden evolucionar con el tiempo. Este trabajo se basó en datos históricos y puede no reflejar necesariamente las prácticas actuales o futuras en cirugía cardíaca.

A pesar de las limitaciones previamente descritas el estudio logró cumplir con los objetivos planteados, así como corroborar la hipótesis inicial, evidenciando la aplicabilidad clínica del modelo diseñado.

Se confirmó la hipótesis que los pacientes sometidos a cirugía cardíaca con circulación extracorpórea pueden ser clasificados previamente al acto quirúrgico, permitiendo prever la necesidad de dispositivos de asistencia ventricular o la modificación de la estrategia quirúrgica hacia opciones que reduzcan el tiempo de CEC.

Objetivos

Objetivo General

Se cumplió con el objetivo general de desarrollar un modelo de clasificación para pacientes sometidos a cirugía cardíaca con bomba de circulación extracorpórea, logrando prever de manera efectiva la necesidad de dispositivos de asistencia ventricular o la posibilidad de modificar la estrategia quirúrgica para reducir los tiempos de circulación extracorpórea.

Objetivos Específicos y Resultados Alcanzados

Se identificaron limitaciones en los scores actuales, justificando la creación de un clasificador específico centrado en tiempos de CEC y en la necesidad de dispositivos de asistencia ventricular.

Se desarrolló un modelo robusto integrando variables clave como BCIAO, edad, sexo, FEY, tipo de cirugía, tipo de válvula, posición de la válvula e hipotermia aplicada logrando una clasificación precisa y clínicamente relevante.

El análisis estadístico demostró que el clasificador propuesto es adecuado para los tipos de cirugías cardíacas propuestas en términos de precisión, sensibilidad y especificidad.

El modelo mostró un desempeño adecuado para identificar pacientes en riesgo, permitiendo anticipar la colocación de dispositivos de asistencia ventricular o ajustar las estrategias quirúrgicas para optimizar los tiempos de CEC.

El clasificador propuesto tiene un impacto positivo en la toma de decisiones médicas, con potencial para ser integrado en la práctica clínica y mejorar los resultados postoperatorios, reduciendo la morbilidad.

El modelo fue capaz de predecir con moderada precisión el intervalo DIFF, sugiriendo cambios quirúrgicos que podrían minimizar ambos tiempos o justificar la colocación precoz de BCIAO.

Hasta el momento la necesidad crítica de tomar decisiones médicas fundamentales durante la cirugía cardíaca, como la elección de utilizar un balón de contrapulsación para el apoyo de la salida de CEC se realiza en el intraoperatorio, muchas veces de manera intempestiva ante la urgencia que demanda la situación o previéndola en el prequirúrgico de acuerdo a la fracción de eyección del ventrículo izquierdo (FEY) como única variable. Además, se agrega complejidad al hecho de que los puntajes de scores de riesgo como STS, EUROSCORE y EUCOSCORE II (o logístico) tienen limitaciones intrínsecas, ya que no proporcionan clasificadores y predicciones específicas para el período preoperatorio e intraoperatorio respectivamente. La solución de este problema es fundamental para mejorar la atención y el resultado de los pacientes sometidos a cirugía cardíaca, asegurando que las decisiones médicas se tomen de manera precisa y oportuna en función de la situación clínica en tiempo real. Esto último constituye el eje del presente trabajo.

BACKGROUND

CIRUGÍA CARDIACA

La cirugía cardiaca es una intervención médica de alto riesgo que se realiza en pacientes con enfermedades cardíacas graves. Durante estos procedimientos, es común la utilización de una bomba de circulación extracorpórea (BCEC/CEC) para mantener la circulación y oxigenación sanguínea mientras el cirujano trabaja en el corazón exangüe del paciente. Sin embargo, la elección de utilizar CEC y determinar la técnica quirúrgica adecuada son decisiones cruciales que deben basarse en una evaluación precisa del estado del paciente.

Los scores STS, EUROSCORE y EUCOSCORE II (o logístico) son herramientas ampliamente utilizadas para evaluar el riesgo quirúrgico y predecir la mortalidad perioperatoria en pacientes sometidos a cirugía cardiaca. Estos scores consideran una serie de factores clínicos, como la edad del paciente, comorbilidades médicas, el tipo de cirugía y otros indicadores relevantes para calcular el riesgo global del paciente.

Sin embargo, la limitación crítica de estos scores es que no ofrecen predicciones específicas para el período intraoperatorio. Su enfoque se centra en proporcionar estimaciones generales de riesgo preoperatorio de manera global ayudando a la toma de decisión sobre el paciente es candidato o no al procedimiento quirúrgico, nada establece si el paciente requerirá BCIAO o no. En el intraoperatorio tampoco predice cuan dificultosa será la salida de CEC. Esto significa que, aunque estos scores son valiosos para evaluar el riesgo global y ayudar en la planificación preoperatoria, no proporcionan orientación directa sobre la necesidad de medidas intraoperatorias específicas, como el uso de un balón de contrapulsación o la adaptación de la técnica quirúrgica en tiempo real.

Por lo tanto, la identificación de datos relevantes para la toma de decisiones preoperatorias e intraoperatorias críticas, como es el uso de BCIAO y la dificultad en la salida de CEC se convierte en un desafío clave. Estos datos podrían incluir información sobre la respuesta hemodinámica del paciente durante la cirugía, la presión arterial, la saturación de oxígeno, la función cardíaca y otros parámetros en tiempo real que pueden guiar las decisiones clínicas. La necesidad de identificar este problema es esencial para garantizar la seguridad y el éxito de las cirugías cardíacas, así como para minimizar los riesgos asociados.

BREVE RESEÑA HISTÓRICA

La historia de la cirugía con CEC está marcada por una serie de avances tecnológicos y médicos que han transformado la cirugía cardiovascular y otros procedimientos quirúrgicos. La idea de utilizar dispositivos para mantener la circulación sanguínea y la oxigenación fuera del cuerpo comenzó a explorarse en la década de 1930. En 1935, el Dr. Paul Zoll realizó experimentos con máquinas de corazón y pulmón, pero los avances

significativos no llegaron hasta después de la Segunda Guerra Mundial. En 1953, el Dr. John Gibbon realizó la primera cirugía cardíaca exitosa con circulación extracorpórea, utilizando una máquina de corazón-pulmón para mantener la circulación y oxigenación durante una operación de reparación de un defecto septal. Este hito abrió la puerta a la cirugía cardíaca moderna.

A medida que se perfeccionaban las técnicas quirúrgicas y los dispositivos de CEC, se desarrollaron nuevos materiales y métodos para minimizar las complicaciones. En las décadas de 1960 y 1970, se introdujeron bombas centrífugas y oxigenadores de membrana, que mejoraron la eficiencia y redujeron el daño a los glóbulos rojos. Con la mejora de las técnicas de CEC, la cirugía cardíaca se amplió en las décadas de 1980 y 1990 para incluir procedimientos más complejos, como el trasplante de corazón, cirugías de revascularización, cirugías de reemplazo valvular, etc. Además, la CEC comenzó a utilizarse en otras áreas de la cirugía, como la neurocirugía y la cirugía pediátrica.

En los últimos años, la investigación se ha centrado en mejorar la biocompatibilidad de los dispositivos de CEC, reducir la inflamación y las complicaciones postoperatorias. También se están explorando técnicas menos invasivas y el uso de asistencia ventricular, que pueden permitir la realización de cirugía con menos dependencia de la CEC tradicional. La cirugía con circulación extracorpórea ha revolucionado la cirugía cardiovascular, permitiendo procedimientos que antes eran imposibles, y se espera que continúe mejorando la seguridad y eficacia de las intervenciones quirúrgicas a medida que la tecnología avanza. Aunque en los últimos años se están realizando, cada vez más, cirugías sin CEC a corazón batiente como las CRM sin CEC con doble arteria mamaria que no requieren para la confección de bypass que el extremo proximal este suturado a la arteria Aorta.




Figura 1: Esquema de la circulación cruzada controlada, en la que un "donante", habitualmente el padre o la madre de un niño, servía como oxigenador para efectuar la cirugía a corazón abierto.




Figura 2: John Gibbon y su esposa Mary Hopkinson (Maly) junto a la máquina corazón-pulmón con la que Gibbon cerró por primera vez una comunicación interauricular con circulación extracorpórea el 6 de mayo de 1953 en el Hospital de la Universidad

CONCEPTO DE CIRCULACIÓN EXTRACORPÓREA

La circulación extracorpórea es un procedimiento médico esencial utilizado en cirugías cardíacas y de bypass coronario. Durante este procedimiento, la sangre del paciente es desviada fuera del corazón y se canaliza a través de una máquina de circulación extracorpórea, también conocida como "bomba de circulación extracorpórea" (BCEC). Esta máquina realiza la función del corazón y los pulmones, oxigenando y filtrando la sangre para mantener la oxigenación y circulación sanguínea mientras el corazón está detenido durante la cirugía, permitiendo al cirujano trabajar en un corazón "seco" y sin latido.

Principales Componentes y Funcionamiento de la Bomba de Circulación Extracorpórea

- **Cánulas de acceso venoso:** Se colocan en grandes venas como la vena cava superior o inferior, desviando la sangre desoxigenada hacia el circuito extracorpóreo. Estas cánulas están conectadas a tubos de silicona o PVC que llevan la sangre a la máquina de circulación extracorpórea.
- **Reservorio venoso:** La sangre venosa que llega al circuito extracorpóreo se almacena en este reservorio. Su diseño permite almacenar suficiente volumen de sangre para un flujo constante y, en algunos casos, filtrar burbujas y micro coágulos.

- **Bomba de sangre (centrífuga o de rodillos):**

Bombas de rodillo: Comprimen un tubo de goma para empujar la sangre de manera continua, aunque pueden generar cierta presión en los tubos.

Bombas centrífugas: Succionan la sangre a través de fuerzas centrífugas, lo cual minimiza el riesgo de daño a las células y permite un control fino del flujo.

- **Oxigenador de membrana:** Es el "pulmón artificial" del sistema, donde la sangre se oxigena y se elimina el dióxido de carbono. La sangre fluye a través de una membrana semipermeable que permite el intercambio gaseoso sin contacto directo entre sangre y oxígeno, reduciendo el riesgo de embolias aéreas.
- **Intercambiador de calor:** Ubicado junto al oxigenador, permite ajustar la temperatura de la sangre para reducir el metabolismo celular del paciente, protegiendo órganos como el cerebro. Se emplea agua tibia o fría para ajustar la temperatura según la estrategia quirúrgica.
- **Filtro arterial:** Filtra burbujas de aire y partículas antes de que la sangre regrese al paciente, previniendo complicaciones graves como embolias aéreas y ACV por coágulos.
- **Cánula de retorno arterial:** Devuelve la sangre oxigenada al paciente, generalmente a través de la aorta, permitiendo la distribución de oxígeno y

nutrientes. El flujo y la presión se ajustan para imitar la circulación natural del paciente.

El Tiempo de Clampeo Aórtico y su Utilidad en la Cirugía

Un elemento crucial en estas cirugías es el tiempo de clampeo aórtico, que se refiere al período en que una pinza especial bloquea temporalmente la aorta, deteniendo el flujo sanguíneo al corazón y aislándolo del resto de la circulación.

Aislamiento del Corazón

Con la aorta clampeada, el corazón se vacía de sangre, proporcionando un entorno libre de flujo para el cirujano, facilitando la precisión en procedimientos delicados.

Protección Miocárdica (Cardioplejía)

Durante el clampeo, el corazón se detiene mediante una solución cardiopléjica rica en potasio, administrada en las arterias coronarias. Esto reduce el consumo de oxígeno, protegiendo el músculo cardíaco. La cardioplejía puede ser fría o tibia y se administra de forma repetida para proteger el tejido en cirugías largas.

Perfusión Sistémica a través de la Bomba de Circulación Extracorpórea

Mientras la aorta está clampeada, la máquina de circulación extracorpórea se encarga de mantener el flujo de sangre al resto del cuerpo, evitando isquemia en los órganos vitales.

El tiempo de clampeo debe ser breve para minimizar el riesgo de lesión por isquemia en el corazón. En general, se considera seguro un tiempo de clampeo entre 60 y 90 minutos, ya que tiempos prolongados pueden aumentar el riesgo de daños, como lesión por isquemia-reperfusión o estrés en el miocardio, lo que puede desencadenar arritmias o insuficiencia cardíaca postoperatoria.

Desclampeo y Restauración de la Función Cardíaca

Cuando finaliza la cirugía, se retira la pinza de la aorta en un proceso conocido como reperfusión, permitiendo que el flujo sanguíneo regrese al corazón. En este momento, el perfusionista ajusta la máquina de circulación extracorpórea para disminuir gradualmente su soporte, permitiendo que el corazón retome sus funciones normales.

Importancia del Control en el Tiempo de Clampeo

Mantener un tiempo de clampeo adecuado es fundamental para reducir el riesgo de daños al miocardio y asegurar la recuperación postoperatoria. El manejo preciso del clampeo y del soporte extracorpóreo garantiza un entorno seguro y controlado para el éxito de la cirugía, protegiendo la función del corazón y los órganos vitales del paciente.




Figura 3: Esquema de un circuito de CEC. Se observa que el drenaje de la sangre venosa proviene de la cánula venosa (azul) directamente de las cavidades derechas del corazón que recoge la sangre proveniente de vena Cava Superior e inferior, de la cánula de aspiración/succión (amarilla) y del venteo de la arteria pulmonar (verde), eso pasa por un filtro, llega al reservorio y recircula hacia el oxigenador de membrana y es devuelta oxigenada como sangre arterial a través de la cánula arterial (roja) inserta en la arteria Aorta. De esta manera la BCEC cumple con la función corazón-pulmón.




Figura 4: Bomba de Circulación Extracorpórea. desde la cual se maneja el volumen minuto, presión y volumen sanguíneo del paciente mientras su corazón está detenido en diástole por solución de cardioplejia fría y rica en potasio, con un campo exangüe por el drenaje venoso, la aspiración y venteo.

IMPORTANCIA DEL TIEMPO DE BOMBA DE CIRCULACIÓN EXTRACORPÓREA

El tiempo de bomba de circulación extracorpórea es un factor crítico en el contexto de la cirugía cardíaca. La duración de este procedimiento puede influir en múltiples aspectos, incluido el riesgo de complicaciones postoperatorias, la respuesta inflamatoria del paciente, la duración total de la intervención quirúrgica y el tiempo de recuperación postoperatoria. Un tiempo prolongado de bomba puede estar asociado con un mayor estrés para los órganos y sistemas del paciente, lo que podría aumentar la probabilidad de complicaciones. Esta respuesta inflamatoria, asociada con trastornos postoperatorios de la hemostasia, es responsable de una significativa morbilidad en cirugía cardíaca (Baufreton et al., 2006).

El síndrome biológico "post-CEC" relacionado con la "bioincompatibilidad" de la CEC, denominado por los anglosajones "Blood Activation," agrupa la activación de numerosas y diversas cascadas fisiopatológicas humorales y celulares (fibrinólisis, coagulación, complemento, leucocitos, plaquetas, etc.) (Baufreton et al., 2006). Según este autor ... "Paradójicamente, esta entidad clínico-biológica ha sido mejor comprendida desde que la cirugía cardíaca sin CEC, es decir, la cirugía coronaria con el corazón latiendo. La respuesta inflamatoria en cirugía cardíaca no desaparece por la ausencia de superficies artificiales. La distinción entre respuesta inflamatoria dependiente de los materiales y respuesta inflamatoria independiente de los materiales es, por lo tanto, hoy en día más pertinente" ... (Baufreton et al., 2006).

En este sentido, y a partir de las cirugías de revascularización miocárdica sin CEC (a corazón latiendo), algunos autores sostienen la hipótesis que el trauma derivado del procedimiento quirúrgico es probablemente el principal determinante de la respuesta inflamatoria y que la CEC solo influye mínimamente en los niveles circulantes de los marcadores inflamatorios. (Esper et al, 2014).

Se debe tener en cuenta que este debate (CRM con vs CRM sin CEC) aún permanece abierto en la comunidad de cirujanos cardiovasculares, si bien es un tema importante y podría "separar las aguas" en cuanto a cuál es el papel de la CEC en la inflamación sistémica postquirúrgica y cual le corresponde al mero acto quirúrgico cuando no hay CEC, se debe considerar que el presente trabajo aborda distintos tipos de cirugía cardíaca con CEC que no pueden prescindir de ésta y no solo se remite a la CRM.

Si bien es necesario hallar un mecanismo para disminuir la respuesta inflamatoria sistémica y sus deletéreos efectos en el postoperatorio por medio de agentes farmacológicos o biológicos únicos o combinados (Levy, J. H., et al 2003), a pesar de los ya existentes en la recuperación cardiovascular, debemos tener en cuenta que todos estos trabajos están centrado en el postoperatorio dejando en la intuición y expertise del cirujano tratante la "necesidad de dispositivos de asistencia ventricular como el BCIA".

FACTORES QUE AFECTAN EL TIEMPO DE BOMBA

Varios factores pueden influir en la duración del tiempo de circulación extracorpórea durante una cirugía cardíaca. Estos factores incluyen la complejidad del procedimiento quirúrgico, la experiencia del equipo médico y perfusionista, el estado de salud preoperatorio del paciente, la técnica quirúrgica utilizada, la necesidad de realizar procedimientos adicionales durante la cirugía (como reparación valvular o corrección de aneurismas) y la disponibilidad de recursos técnicos adecuados para realizar la perfusión cardiopulmonar.

Estudios previos sobre el tiempo de bomba

Una revisión bibliográfica de estudios e investigaciones previas sobre el tiempo de bomba de circulación extracorpórea ha arrojado diversas conclusiones relevantes. Por ejemplo, algunos estudios han demostrado una asociación entre tiempos prolongados de bomba y un mayor riesgo de complicaciones, como daño renal agudo o síndrome de respuesta inflamatoria sistémica. Otros estudios han explorado técnicas y estrategias para reducir la duración del tiempo de bomba y han sugerido que la optimización del manejo perioperatorio y la selección adecuada de pacientes pueden tener un impacto positivo.

Complicaciones asociadas con un tiempo prolongado de bomba

Un tiempo prolongado de circulación extracorpórea puede estar relacionado con complicaciones significativas en el paciente. Entre ellas se encuentran sangrados y trastornos de la coagulación, hemólisis, inflamación sistémica, reacción alérgica o inflamatorias a materiales y drogas utilizadas (heparina, protamina, etc.), hemodilución y su consecuente anemia, alteraciones metabólicas, complicaciones neurológicas, disfunción pulmonar, renal o hepática (Kirklin et al, 2012)

Es importante destacar que no todos los pacientes experimentarán estas complicaciones, y muchas de ellas se pueden gestionar y prevenir con cuidado y monitoreo adecuados durante y después de la cirugía (recuperación cardiovascular). La gestión de riesgos y la atención especializada son esenciales para minimizar el impacto de estas complicaciones potenciales.

Estrategias para reducir el tiempo de bomba

Con el objetivo de reducir el tiempo de bomba de circulación extracorpórea sin comprometer la seguridad y la efectividad de la cirugía cardíaca, se han propuesto diversas estrategias. Estas incluyen el uso de dispositivos de asistencia circulatoria que minimizan la necesidad de la perfusión prolongada, el desarrollo de técnicas quirúrgicas más eficientes y menos invasivas, así como la optimización del manejo del paciente en el período perioperatorio.

La situación ideal sería no requerir de la CEC, lo cual solo se ha logrado en algunos tipos específicos de cirugía como la Cirugía de revascularización miocárdica (CRM) popularizada como bypass, que se realizan a corazón latiendo por equipos quirúrgicos entrenados, y procedimientos de hemodinamia que son sugeridos a pacientes que por su riesgo no podrán afrontar una cirugía cardíaca, por ejemplo TAVI ("Implante

Transcatéter de Válvula Aórtica" o "Transcatheter Aortic Valve Implantation" en inglés que es la opción a la cirugía de reemplazo valvular aórtico, siendo esta última al momento considerada "Gold Standard".

Balón de contrapulsación intraaórtica

El balón de contrapulsación intraaórtica (BCIAO) es un dispositivo utilizado en medicina cardiovascular para mejorar la función cardíaca en pacientes con insuficiencia cardíaca aguda o shock cardiogénico. Su diseño consta de varias partes clave que le permiten inflarse y desinflarse de manera sincrónica con el ciclo cardíaco, utilizando helio como gas de inflado debido a sus propiedades físicas específicas.

PARTES DEL BALÓN DE CONTRAPULSACIÓN INTRAAÓRTICA El dispositivo tiene tres componentes principales:

- **Catéter:** Generalmente está hecho de poliuretano o materiales biocompatibles. Es el tubo a través del cual se inserta el balón en la arteria. El catéter se introduce típicamente a través de la arteria femoral y avanza hasta la aorta descendente distal a la emergencia de la arteria subclavia izquierda para no limitar el flujo sanguíneo en el miembro superior. Tiene un puerto de inflado que es el canal por el cual el gas (helio) entra y sale del balón para provocar la inflado y desinflado del mismo.
- **Balón:** Un balón flexible de poliuretano o látex, diseñado para inflarse de forma controlada en la aorta torácica. Se coloca en la aorta torácica descendente distal a la arteria subclavia izquierda y proximal a las arterias renales. Se infla durante la diástole, aumentando la presión en la aorta, y se desinfla en la sístole, disminuyendo la poscarga del corazón. Este proceso mejora el flujo sanguíneo coronario y reduce el esfuerzo cardíaco.
- **Consola de control:** Controla la inflación y desinflación del balón a través de un sistema que utiliza helio como gas propulsor. Sincroniza el inflado del balón con la actividad cardíaca, utilizando el electrocardiograma (ECG) del paciente o la presión arterial. Esta sincronización es crucial para que el balón se infle durante la diástole y se desinfe justo antes de la sístole. Proporciona información en tiempo real sobre los cambios de presión en la aorta, permitiendo al equipo quirúrgico evaluar su correcto funcionamiento y a los cardiólogos el control del paciente en la recuperación cardiovascular.

EL USO DE HELIO

El BCIAO utiliza helio como gas para inflar y desinflar el balón debido a las siguientes razones:

- **Bajo peso molecular:** El helio es un gas liviano con una densidad significativamente menor que el aire, lo que permite que se mueva rápidamente dentro y fuera del balón. Esto es crucial porque el ciclo cardíaco tiene tiempos muy específicos, y el gas debe ser lo suficientemente rápido para garantizar la sincronización precisa con el latido cardíaco.
- **Bajo riesgo de embolización:** En caso de una fuga o ruptura del balón, el helio, debido a su bajo peso molecular, se disuelve fácilmente en el torrente sanguíneo

y se elimina rápidamente sin causar embolias o complicaciones graves. Otros gases, como el aire o el nitrógeno, podrían causar burbujas en la sangre (embolia gaseosa) si se liberaran accidentalmente.

- Compatibilidad con cambios de temperatura: El helio es inerte y tiene excelentes propiedades térmicas, lo que permite un control preciso del inflado y desinflado del balón, independientemente de las variaciones de temperatura dentro del sistema circulatorio.

PROCESO DE FUNCIONAMIENTO

El balón se infla y desinfla en sincronía con el ciclo cardíaco utilizando la siguiente secuencia:

- Diástole: El balón se infla en la aorta torácica descendente justo después del cierre de la válvula aórtica. Este inflado aumenta la presión en la aorta, lo que a su vez mejora la perfusión coronaria y aumenta el suministro de oxígeno al miocardio (músculo cardíaco). También mejora el flujo sanguíneo sistémico a otros órganos.
- Sístole: Justo antes de que el corazón se contraiga, el balón se desinfla. Esto reduce la presión en la aorta, facilitando la expulsión de sangre desde el ventrículo izquierdo, lo que disminuye la poscarga cardíaca (la resistencia contra la cual el corazón debe bombear). Esto alivia el esfuerzo cardíaco y mejora el gasto cardíaco.

INDICACIONES

El uso del BCIAO se recomienda principalmente en situaciones críticas donde se necesita asistencia hemodinámica.

- Shock cardiogénico: Se utiliza para estabilizar a los pacientes que sufren de shock cardiogénico, comúnmente después de un infarto agudo de miocardio. El BCIAO puede mejorar temporalmente la perfusión y reducir el estrés del corazón mientras se planifican otras intervenciones (por ejemplo, revascularización). (Dr. Cal Shipley, M.D. Animación).
- Insuficiencia cardíaca aguda: En pacientes con insuficiencia cardíaca avanzada que no responden a la terapia farmacológica, el BCIAO puede proporcionar soporte circulatorio mientras se espera una intervención más definitiva, como un trasplante cardíaco.

CONTRAINDICACIONES ESPECÍFICAS

Algunas contraindicaciones importantes incluyen:

- Insuficiencia aórtica significativa: Dado que el inflado del balón aumentaría el reflujo aórtico y empeoraría la sobrecarga de volumen en el ventrículo izquierdo.
- Aneurisma aórtico disecante: El uso del BCIAO podría empeorar la disección o incluso provocar una ruptura.
- Trombosis aórtica o arterial: El dispositivo podría desprender los trombos y causar embolias distales.

- Enfermedad arterial periférica grave: Podría impedir el acceso seguro y aumentar el riesgo de complicaciones vasculares.
- Infección activa en el sitio de inserción: El riesgo de diseminación de la infección es elevado si se inserta el catéter en un sitio infectado.
- Coagulopatías: Pacientes con trastornos de coagulación graves presentan un alto riesgo de sangrado con la colocación del BCIAO, lo que puede aumentar el riesgo de hemorragia grave.
- Soporte en cirugía cardíaca: El BCIAO puede utilizarse durante cirugías cardíacas complejas para proteger al corazón, permitir la salida de BCEC y facilitar la recuperación postoperatoria.



Figura 5: Balón de Contrapulsación Intraaórtica. A la derecha se aprecia la consola, en el centro el balón propiamente dicho y a la izquierda la ubicación del mismo entre la emergencia de la arteria Subclavia izquierda y las arterias renales.

MATERIALES Y MÉTODOS

En este apartado se describe el tipo de estudio, como se generó la base de datos, los modelos de clasificación y predicción en los que se centra este trabajo, los métodos estadísticos utilizados, los algoritmos de Machine Learning, y las herramientas computacionales utilizadas.

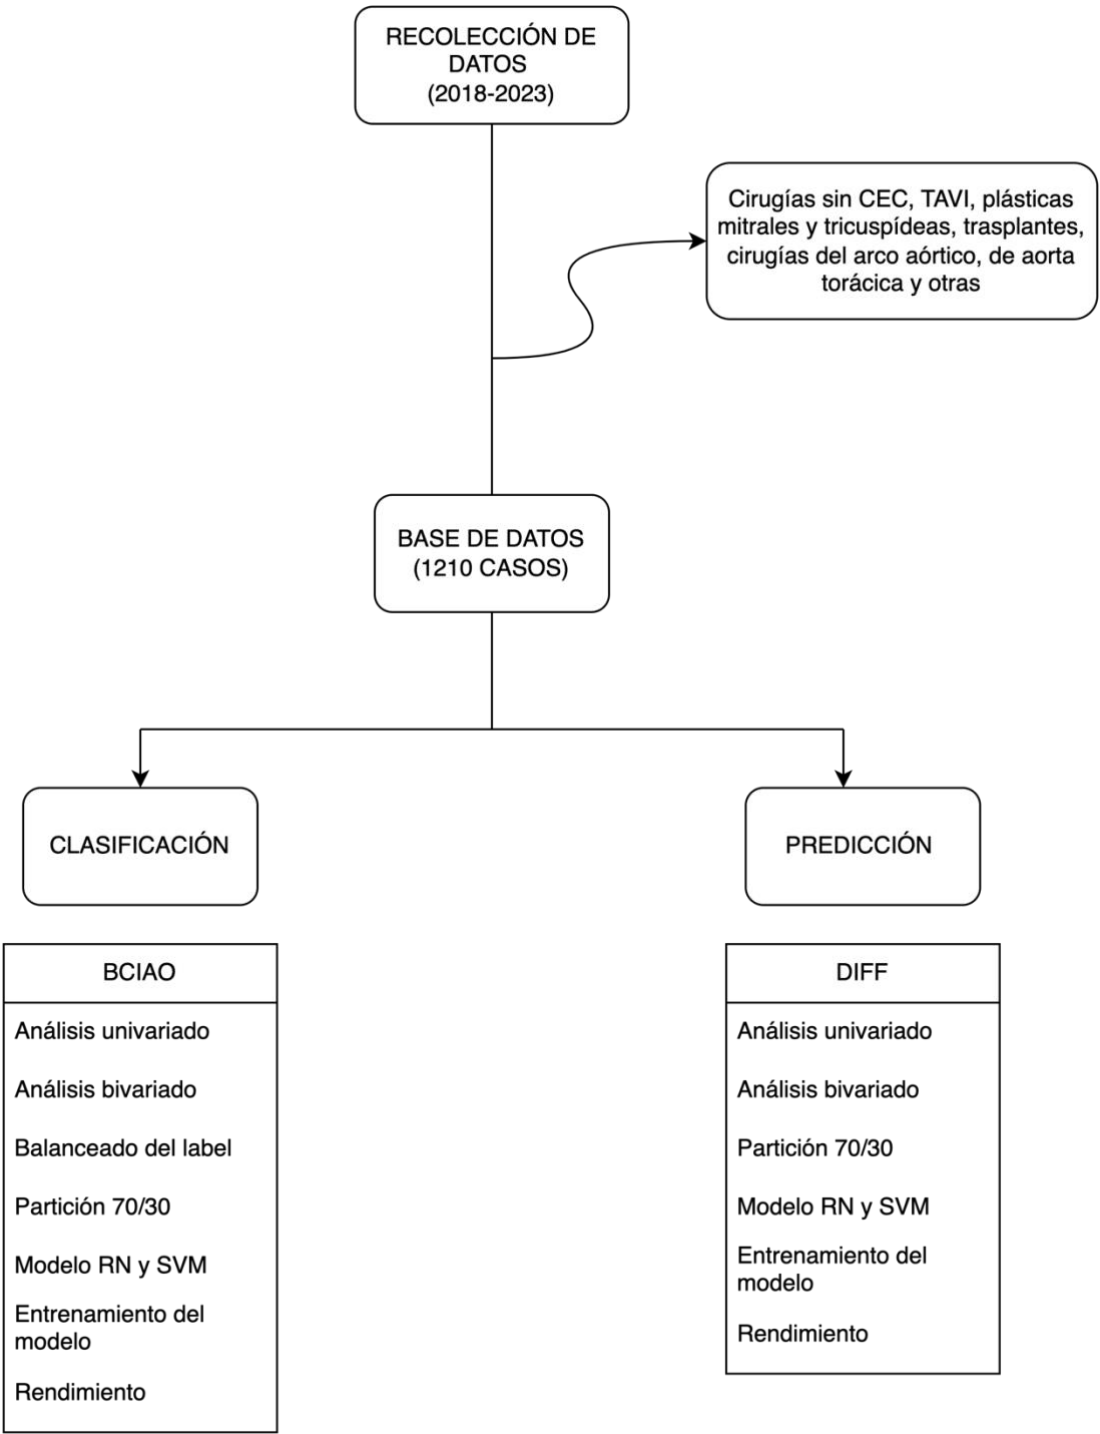


Gráfico 6 : Flujo de trabajo para el análisis de pacientes sometidos a cirugía cardíaca con circulación extracorpórea. Elaboración propia.

DESCRIPCIÓN DEL DISEÑO DEL ESTUDIO

El estudio es de diseño retrospectivo y observacional, ya que se basa en la recolección y análisis de datos históricos de pacientes sometidos a cirugía cardíaca con bomba de circulación extracorpórea (CEC) entre enero de 2018 y junio de 2023. Al ser retrospectivo, se utilizan registros de partes quirúrgicos existentes, lo que permite analizar la evolución y los resultados de los pacientes sin intervenir directamente en el proceso. El enfoque observacional implica que no se modifican las condiciones de los pacientes ni se realizan intervenciones adicionales, limitándose a observar las relaciones entre las variables de interés, como el tiempo de bomba, tipos de cirugía, FEY, entre otras y la necesidad de asistencia ventricular, con el objetivo de desarrollar un modelo de clasificación (preoperatorio). Así como la utilización de las mismas variables para predecir la dificultad de salida de CEC en un modelo de predicción (intraoperatorio)

RECOLECCIÓN DE DATOS

La recolección de datos se realizó a partir de los partes quirúrgicos de dos instituciones de salud privada, donde todas las cirugías fueron llevadas a cabo por el mismo cirujano cardiovascular, aunque formando parte de dos equipos diferentes. Los datos incluyen información relevante sobre los pacientes sometidos a cirugía cardíaca con bomba de circulación extracorpórea (CEC) entre enero de 2018 y junio de 2023. Las variables recolectadas abarcan aspectos demográficos, como edad y sexo; variables clínicas y quirúrgicas, como el tipo de cirugía (bypass coronario, reemplazo valvular, etc.), el número de bypass, y medidas intraoperatorias como el tiempo de bomba, el tiempo de clampeo y la necesidad de BCIAO.

Se logró construir una base de datos con un total de 1.210 registros. En el proceso de limpieza de la misma, se excluyeron distintos tipos de cirugías que complejizaban el estudio debido a su escasa cantidad y poca relevancia estadística. Entre las cirugías eliminadas se encuentran los trasplantes cardíacos, cirugías del arco aórtico, cirugías de aorta descendente, combinaciones más complejas de otras cirugías y cirugías sin CEC. Esto permitió concentrar el análisis en las intervenciones más comunes y relevantes para los objetivos del estudio.

VARIABLES/FEATURES ANALIZADAS

Variable	Tipo de variable	Descripción
BCIAO	Cualitativa dicotómica (dependiente)	Indica si el paciente requirió el uso de balón de contrapulsación intraaórtico (SIN BCIAO/CON BCIAO).

Variable	Tipo de variable	Descripción
Sexo	Cualitativa dicotómica (independiente)	Género del paciente (F = Femenino, M = Masculino).
Edad	Cuantitativa discreta (independiente)	Edad del paciente en años.
Tipo de Cirugía	Cualitativa nominal politómica (independiente)	Clasificación de las cirugías realizadas con CEC, incluyendo: CRM (Cirugía de Revascularización Miocárdica) CRVAo (Cirugía de Reemplazo Valvular Aórtico) CRVM (Cirugía de Reemplazo Valvular Mitral) CRVAo+CRVM (Doble Valvular) CRVAo/CRVM + CRM (Combinados) CIA (Cierre de Comunicación Interauricular) CIV (Cierre de Comunicación Interventricular) BENTALL (Reemplazo Valvular Aórtico + Aorta Ascendente) BENTALL+CRM (Bentall + Revascularización Miocárdica) RAA (Reemplazo de Aorta Ascendente)
Nº de Bypass	Cuantitativa discreta (independiente)	Número de bypass coronarios realizados en CRM. A mayor número de bypass, mayor tiempo de bomba.
Bypass Arteriales	Cuantitativa discreta (independiente)	Número de bypass arteriales coronarios realizados en CRM Arteria Mamaria Interna.
Bypass Venosos	Cuantitativa discreta (independiente)	Número de bypass venosos coronarios realizados en CRM utilizando Vena Safena Interna.
Tiempo de Bomba	Cuantitativa discreta (independiente)	Tiempo en minutos desde el inicio de la circulación extracorpórea hasta la salida de la bomba.
Tiempo de Clampeo	Cuantitativa discreta (independiente)	Tiempo en minutos en que se utilizó el clampeo aórtico durante la cirugía, incluyendo parada cardíaca, cierre de heridas cardíacas, llenado y venteo del corazón.
Válvula	Cualitativa dicotómica (independiente)	Tipo de válvula MECANICA o BIOLOGICA.
Posición	Cualitativa nominal politómica (independiente)	Posición en que se coloca la válvula AORTICA, MITRAL O AORTICA+MITRAL.
Hipotermia	Cualitativa dicotómica (independiente)	Hipotermia a la que se lleva al paciente durante la cirugía LEVE (32-35°C) o MODERADA (28-31°C). Hay otros grados de hipotermias PROFUNDA (18-27°C) pero corresponden a cirugías que no han sido incluidas en este trabajo.

Tabla 1 : La tabla resumen que muestra el tipo y características de las variables/features analizadas.
Elaboración propia.

BREVE DESCRIPCIÓN DE LAS CATEGORÍAS DE LA VARIABLE CIRUGÍA

CRM (Cirugía de Revascularización Miocárdica): Es una cirugía cardíaca en la que se realiza uno o más bypass coronario para llevar flujo sanguíneo distal a la obstrucción de las arterias coronarias con injertos, generalmente de venas safena o arterias mamarias/radiales.

CRVAo (Cirugía de Reemplazo Valvular Aórtico): Consiste en reemplazar la válvula aórtica dañada o enferma con una válvula protésica (biológica o mecánica), lo que permite restaurar su funcionalidad entre el ventrículo izquierdo y la arteria Aorta.

CRVM (Cirugía de Reemplazo Valvular Mitral): Se reemplaza la válvula mitral cuando está dañada o afectada por enfermedad con una válvula protésica (biológica o mecánica), con el objetivo de restablecer la función normal de la válvula entre las cavidades auricular izquierda y ventricular izquierda del corazón.

CRVAo+CRVM (Doble Valvular): Es una cirugía combinada en la que se reemplazan tanto la válvula aórtica como la válvula mitral, corrigiendo problemas en ambas estructuras simultáneamente.

CRVAo/CRVM + CRM (Combinados): Procedimiento quirúrgico en el que se realiza el reemplazo de una válvula (aórtica o mitral) junto con una cirugía de revascularización miocárdica (bypass coronario).

CIA (Cierre de Comunicación Interauricular): Es una cirugía para reparar una comunicación anómala entre las dos aurículas del corazón, cerrando el defecto congénito que permite el paso de sangre entre ellas.

CIV (Cierre de Comunicación Interventricular): Similar a la CIA, pero en este caso la cirugía se realiza para corregir una abertura entre los dos ventrículos del corazón, evitando el flujo anómalo de sangre entre ellos.

BENTALL (Reemplazo Valvular Aórtico + Aorta Ascendente): Es una cirugía compleja en la que se reemplaza tanto la válvula aórtica como la parte ascendente de la aorta con un injerto, generalmente en casos de aneurisma con disfunción valvular grave.

BENTALL+CRM (Bentall + Revascularización Miocárdica): Combina el procedimiento de Bentall con una cirugía de revascularización miocárdica, abordando problemas tanto en la aorta como en las arterias coronarias en una misma intervención.

RAA (Reemplazo de Aorta Ascendente): Cirugía que reemplaza la aorta ascendente, generalmente para tratar aneurismas, disecciones o úlceras aórticas, utilizando un injerto para restaurar la funcionalidad de la arteria.

CREACIÓN VARIABLE ("DIFF")

La variable "DIFF" se generará como una nueva medida derivada de la diferencia entre el tiempo total de bomba y el tiempo de clampeo aórtico. Esta variable tiene como propósito cuantificar la dificultad en la salida de circulación extracorpórea al restar el tiempo que el corazón permanece bajo clampeo del tiempo total en el que el paciente está bajo circulación extracorpórea.

$$DIFF = \text{Tiempo de Bomba} - \text{Tiempo de Clampeo}$$

El valor de DIFF podría ser un indicador clave del status cardíaco del paciente durante la cirugía, reflejando cómo responde el corazón al proceso de revascularización y perfusión una vez removido el clampeo. Un valor elevado de DIFF podría sugerir que el corazón del paciente está teniendo dificultades para reiniciar su función normal, lo que aumenta la probabilidad de requerir medidas adicionales de soporte hemodinámico, como el uso del balón de contrapulsación intraaórtico (BCIAO).

Es importante destacar que, aunque la variable DIFF podría ser una métrica valiosa para evaluar la dificultad en la salida de circulación extracorpórea y su posible relación con la necesidad de asistencia ventricular mediante BCIAO, su uso en la fase preoperatoria está limitado. Dado que DIFF solo puede calcularse una vez concluida la cirugía, es decir, tras la finalización del tiempo de clampeo y de bomba, esta variable no puede ser utilizada en un modelo de clasificación para anticipar la necesidad de BCIAO antes del inicio de la cirugía.

La predicción preoperatoria de la probabilidad de requerir BCIAO es fundamental para la planificación quirúrgica, y dicha predicción debe basarse en variables disponibles previas al acto quirúrgico, como la edad, sexo, tipo de cirugía, fracción de eyección del ventrículo izquierdo (FEV), entre otras. Aunque DIFF no puede ser utilizada para esta anticipación, su análisis posterior permite validar y comprender mejor los factores intraoperatorios que influyen en la necesidad de BCIAO, proporcionando un marco de retroalimentación útil para futuras cirugías, además de prever cuán dificultosa será la salida de CEC, dato muy útil a la hora de decidir la estrategia quirúrgica.

ANÁLISIS EXPLORATORIO DE DATOS

Se llevo a cabo un análisis exploratorio de datos en el que se utilizaron técnicas para identificar tendencias y detectar valores atípicos, tanto en variables cualitativas como cuantitativas.

Análisis univariado:

- Variables cualitativas: Se realizaron tablas de frecuencia, porcentajes y gráficos de barras para visualizar la distribución de las variables sexo, tipo de cirugía, posición, hipotermia, válvula y BCIAO. Estas visualizaciones permiten identificar la prevalencia de cada categoría y evaluar si existe alguna tendencia destacable.
- Variables cuantitativas: Para las variables numéricas como edad, fracción de eyección del ventrículo izquierdo (FEY), tiempo de bomba, tiempo de clampeo y la variable creada DIFF, se realizaron histogramas que muestran su distribución. También se aplicaron pruebas de normalidad (Shapiro-Wilk) para determinar si las variables siguen una distribución normal. Dado que no lo hicieron, se optó por medidas como la mediana, los cuartiles, el mínimo y el máximo para describirlas.

Identificación de valores atípicos:

Para las variables cuantitativas, se utilizaron Boxplots para visualizar posibles valores atípicos. Esta técnica permitió observar visualmente cualquier dato extremo en las distribuciones de las variables. La existencia de valores atípicos también se evaluó mediante resúmenes estadísticos (mínimos y máximos) para cada variable numérica.

Análisis bivariado:

En este caso particular del análisis bivariado se dividió en dos apartados: preoperatorio e intraoperatorio.

Preoperatorio

Se investigaron las relaciones entre la variable BCIAO (uso de balón de contrapulsación intraaórtico) y el resto de las variables cuantitativas y cualitativas.

Para las variables cuantitativas, como DIFF, edad y FEY, se utilizó la prueba de Wilcoxon-Mann-Whitney para comparar las distribuciones entre los grupos de BCIAO (con/sin). Se confeccionaron gráficos Boxplot a fin de comparar la mediana de la variable cuantitativa en cada categoría de BCIAO.

Para las variables cualitativas, como sexo, tipo de cirugía, válvula, y posición, se realizaron tablas de contingencia y pruebas de Chi-cuadrado, Fisher o Fisher con simulación de Monte Carlo, cuando las frecuencias esperadas eran bajas y no cumplieron los supuestos de este método, con el fin de identificar posibles asociaciones

entre estas variables y BCIAO. Estas relaciones se visualizaron mediante gráficos de barras apiladas que muestran las proporciones dentro de cada grupo. Se confeccionaron tablas resumen de ambos tipos de variables para cada categoría de la variable BCIAO con sus respectivos P valor.

Intraoperatorio

En este apartado se evalúa la relación de variable DIFF con el resto de variables cuantitativas y cualitativas.

Correlación entre covariables:

Se analizaron correlaciones entre las variables cuantitativas utilizando el coeficiente de correlación de Spearman, dado que las variables no presentaban una distribución normal. Esto permitió identificar correlaciones potenciales entre variables como edad, FEY, y DIFF. Gráficos de pares (scatter plots) ayudaron a visualizar estas relaciones.

Se utilizó el modelo LOESS (Locally Estimated Scatterplot Smoothing) que es un método de regresión no paramétrica utilizado para modelar relaciones entre variables sin asumir una forma funcional específica (como lineal o cuadrática). Con ello se logró suavizar gráficos de dispersión para observar tendencias generales entre las dos variables en estudio.

Para las variables cualitativas inicialmente se intentó realizar el método de ANOVA dado que es lo suficientemente robusto para ser usado en distribuciones que se apartan de la normalidad, para ello se testeó el supuesto de homocedasticidad (igualdad de varianzas) con el test de Levene, dado su incumplimiento se realiza un anova no paramétrico ANOVA de Welch (One Way ANOVA), en el caso de variable con varias categorías se realiza la comparación por pares de Bonferroni.

También se utilizó Wilcoxon-Mann-Whitney que se puede aplicar cuando la variable dependiente es cuantitativa (en este caso DIFF).

Finalmente se muestran los resultados en gráficos Boxplots y tablas de comparaciones múltiples.

DIVISIÓN DE LA MUESTRA

Posterior a la generación de un subset balanceado por undersampling la muestra fue dividida en dos subconjuntos: un conjunto de entrenamiento y un conjunto de testeo. Para esta partición, se asignó un 70% de los datos al entrenamiento y el 30% restante al testeo. Este procedimiento asegura que el modelo pueda ser entrenado con la mayoría de los datos, mientras se reserva una porción para evaluar su rendimiento en datos no vistos. La partición se realizó utilizando la función `createDataPartition` de la librería

caret, que garantiza que ambas muestras mantengan la proporción original de la variable de interés BCIAO (uso de balón de contrapulsación intraaórtico).

- Conjunto de entrenamiento: contiene el 70% de los datos totales y se utiliza para ajustar el modelo de clasificación.
- Conjunto de testeo: el 30% restante se reserva para evaluar el rendimiento del modelo en predicciones.

MODELO DE CLASIFICACIÓN (PREOPERATORIO)

Entrenamiento del modelo

Se optó por dos modelos, una Red Neuronal como técnica de clasificación, debido a su capacidad para manejar relaciones no lineales complejas entre las variables y SVM (Máquina de Vectores de Soporte). Para entrenar el modelo, se utilizaron las siguientes variables predictoras: sexo, edad, FEY, tipo de cirugía, válvula, posición e hipotermia. El modelo fue ajustado utilizando la función train de la librería caret, donde se ajustaron los hiperparámetros del modelo, como el número de neuronas en la capa oculta y el parámetro de regularización en la RN y Cost y Sigma para el SVM. Se realizó escalado automático de las covariables cuantitativas. El número máximo de iteraciones durante el entrenamiento fue de 300.

Durante el entrenamiento del modelo, se utilizó una técnica de validación cruzada de 5-folds, que consiste en dividir el conjunto de entrenamiento en 5 subconjuntos y entrenar el modelo en 4 de ellos, utilizando el quinto para validación. Este proceso se repite 5 veces, alternando los subconjuntos, con el fin de minimizar el sesgo en la evaluación del modelo.

Se presentan gráficos de Accuracy según Decay para las distintas cantidades de neuronas en la capa oculta, de la arquitectura de la RED, de accuracy según Cost y Sigma e importancia de las variables en el modelo.

Validación del Modelo

Una vez entrenados el modelo con ambos métodos, se evaluó su rendimiento en el conjunto de testeo. Las predicciones generadas por el modelo fueron comparadas con los valores reales de BCIAO en el conjunto de testeo. Para medir el rendimiento se utilizó la matriz de confusión, que permite calcular métricas como:

Exactitud (accuracy): el porcentaje de predicciones correctas.

Sensibilidad (recall): la capacidad del modelo para identificar correctamente los casos positivos (uso de BCIAO).

Especificidad: la capacidad del modelo para identificar correctamente los casos negativos (no uso de BCIAO).

Precisión: proporción de verdaderos positivos en las predicciones positivas (es decir, el PPV), que indica la exactitud al clasificar como positivos.

Tasa de error: proporción de predicciones incorrectas respecto al total de predicciones.

Kappa: mide la concordancia entre predicciones y resultados reales, ajustando por coincidencias al azar. Valores cercanos a 1 indican alta concordancia.

McNemar's Test: evalúa si existe una diferencia significativa entre las tasas de error de dos modelos, útil para comparar modelos sobre el mismo conjunto de datos.

Valor predictivo positivo (PPV o Precisión): porcentaje de predicciones positivas correctas respecto a todas las predicciones positivas. Mide la exactitud al predecir casos positivos.

Valor predictivo negativo (NPV): porcentaje de predicciones negativas correctas respecto a todas las predicciones negativas. Indica la exactitud al predecir casos negativos.

Prevalencia: proporción de casos positivos reales en el conjunto de datos. Representa la frecuencia de la clase positiva.

Tasa de detección (Detection Rate): proporción de verdaderos positivos respecto al total de casos en el conjunto. Mide la frecuencia con la que se identifica correctamente la clase positiva.

Prevalencia de detección (Detection Prevalence): frecuencia de predicciones positivas respecto al total. Indica cuántos casos se clasifican como positivos.

Balanced Accuracy: promedio entre la sensibilidad y la especificidad, útil cuando las clases están desbalanceadas.

F1 Score: promedio armónico entre precisión (PPV) y sensibilidad (recall). Es una métrica de desempeño global para la clase positiva.

El uso de la matriz de confusión y las métricas derivadas permitió evaluar de manera integral el rendimiento del modelo de red neuronal y SVM, tanto en su capacidad para clasificar correctamente los casos positivos como los negativos, proporcionando una visión clara de su efectividad y posibles áreas de mejora.

Se presentan gráficos de área bajo la curva, gráficos de comportamiento de las métricas en función del umbral.

Modelo de Predicción (Intraoperatorio)

En este caso se utilizó la base de datos original sin necesidad de balanceado dado que la variable a predecir es una variable cuantitativa continua. La base de datos se partición o en un 70 % de los datos para el grupo de entrenamiento y un 30 % de los datos para el grupo de testeo. Se evaluó estadísticos como media, mediana y rango en la base de datos original así como en el conjunto de entrenamiento y testeo a fin de evaluar que la variable DIFF mantenga una distribución similar de las particiones con la base de datos original.

Entrenamiento del modelo

Se utilizaron nuevamente como métodos para la predicción de DIFF una red neuronal y SVM. Para entrenar el modelo, se utilizaron las siguientes variables predictoras: sexo, edad, FEY, tipo de cirugía, válvula, posición e hipotermia. El modelo fue ajustado utilizando la función train de la librería caret, donde se ajustaron los hiperparámetros del modelo, como Size y Decay para la RN y Cost y Sigma para el SVM. El número máximo de iteraciones fue 300 y en todos los casos se realizó validación cruzada de 5 folds. Se presenta gráfico de importancia de las variables en el modelo.

Validación del Modelo

Se evaluó su rendimiento en el conjunto de testeo. Para medir el rendimiento se utilizaron métricas como:

R^2 (Coeficiente de Determinación):

Mide la proporción de la variabilidad de la variable dependiente (real) que el modelo puede explicar

RMSE (Root Mean Squared Error):

Es la raíz cuadrada del promedio de los errores al cuadrado entre los valores predichos y los valores reales. Mide la magnitud promedio de los errores de predicción. Un RMSE más bajo indica un modelo con predicciones más precisas.

MAE (Mean Absolute Error):

Es el promedio de las diferencias absolutas entre los valores predichos y los reales. Representa el error promedio sin considerar la dirección del error. El MAE es más robusto frente a errores extremos o atípicos.

Se presenta gráficos de dispersión de predicciones vs valores reales y distribución de residuos.

Ambos modelos (RN y SVM) se entrenaron y validaron CON y SIN outliers de la variable DIFF a fin de identificar como estos valores atípicos podrían afectar al modelo.

HERRAMIENTAS

Para el análisis y desarrollo del modelo de clasificación, se utilizó R Studio, versión 4.2.2 (2022). En este entorno, se emplearon las siguientes librerías, cada una con un propósito específico dentro del flujo de trabajo:

Librería	Descripción
arsenal	Análisis descriptivos y comparativos mediante tablas personalizadas.
car	Análisis de regresiones y verificación de supuestos estadísticos.
caret	Entrenamiento de modelos de clasificación, partición de datos y validación cruzada.
dplyr	Manipulación y limpieza de datos, facilitando tareas como filtrado, selección y agrupación.
flextable	Creación de tablas flexibles y personalizables para informes en Word y otros formatos.
GGally	Extensión de ggplot2, útil para generar gráficos de correlación y pares (scatter plots).
ggplot2	Creación de gráficos personalizados, como histogramas y gráficos de barras y boxplots.
gridExtra	Combinación de múltiples gráficos en una misma figura.
Hmisc	Análisis estadísticos y manejo de datos.
knitr	Generación de informes dinámicos y presentación de resultados reproducibles.
MASS	Funciones estadísticas avanzadas y modelos lineales generalizados.
NeuralNetTools	Visualización de redes neuronales.
nnet	Construcción de redes neuronales.
openxlsx	Importación y exportación de archivos Excel.
PerformanceAnalytics	Herramientas para el análisis y visualización de métricas de desempeño.
pROC	Análisis de curvas ROC y evaluación del desempeño de modelos de clasificación.
RColorBrewer	Proporciona paletas de colores estéticas para gráficos.
rgl	Creación de gráficos 3D interactivos en R.
scales	Escalado y formateo de datos numéricos y gráficos ggplot2, proporciona herramientas para ajustar escalas.

Tabla 2 : Nombre y descripción de las Librerías que se utilizaron en R Studio para la realización del trabajo

RESULTADOS

Resultados del análisis descriptivo

ANÁLISIS UNIVARIADO

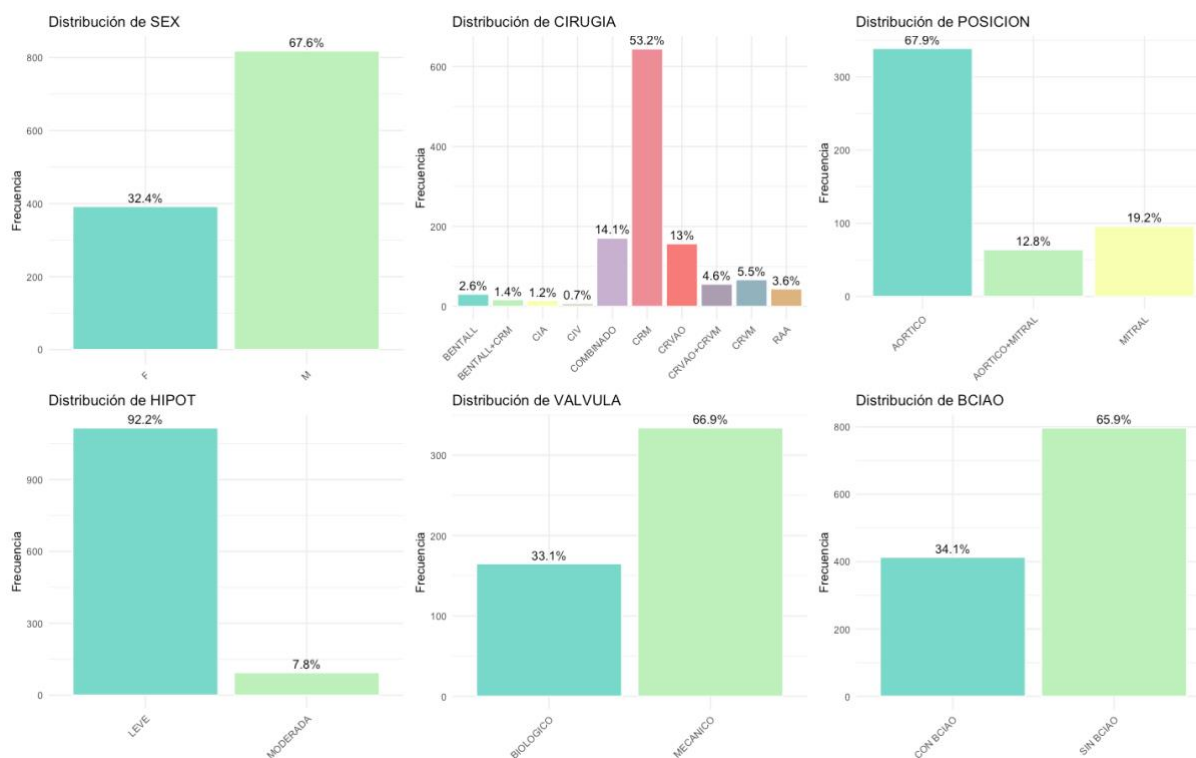


Figura 7: Distribución de las variables cualitativas. 1 SEXO (F=32.4%, M=67.6%). 2 CIRUGIA (BENTALL=2.6%, BENTALL+CRM=1.4%, CIA=1.2%, CIV=0.7%, COMBINADO=14.2%, CRM=53.2%, CRVAO=13%, CRVAO+CRVM=4.8%, CRVM=5.5%, RAA=3.6%). 3 POSICION (AORTICO=67.9%, AORTICO+MITRAL= 12.8%, MITRAL=19.2%). 4 HIPOTERMIA (LEVE=92.2%, MODERADA=7.8%). 5 VALVULA (BIOLOGICO= 33.1%, MECANICO=66.9%). 6 BCIAO (CON BCIAO= 34.1%, SIN BCIAO= 66.9%). Elaboración propia.

	Recuento	Porcentaje
SEXO		
MASCULINO	818	67.6%
FEMENINO	392	32.4%
CIRUGIA		
CRM	644	53.2%
COMBINADO	171	14.1%
CRVAO	157	13%
CRVM	67	5.5%

	Recuento	Porcentaje
POSICION	339	67.9%
AÓRTICO	96	19.2%
MITRAL	64	12.8%
AORTICO+MITRAL		
HIPOT		
LEVE	1116	92.2%
MODERADA	94	7.8%
VALVULA		
MECÁNICO		
BIOLÓGICO	334	66.9%
	165	33.1%
BCIAO		
SIN BCIAO	797	65.9%
CON BCIAO	413	34.1%

Tabla 3 : La tabla resumen de variables categóricas donde se muestra recuento y porcentaje de las distintas categorías dentro de cada variable/feature.

Esta distribución muestra una mayor representación de pacientes masculinos en el conjunto de datos.

La revascularización coronaria (CRM) y las intervenciones en posición aórtica son las más frecuentes. Otras categorías, como CRVM (5.5%), CRAVAO+CRVM 4.6% y RAA (3.6%), muestran menor representación. Algunas intervenciones más específicas, como BENTALL, BENTALL+CRM, CIA y CIV, tienen una frecuencia inferior al 3%.

Esto indica que los procedimientos más comunes en el conjunto de datos, exceptuando la CRM, se concentran en la posición aórtica. Y cuando la cirugía implica una CRVAO el uso de válvulas mecánicas es preferido sobre las biológicas.

La gran mayoría de los casos de hipotermia son leves. No se observa ninguna categoría con hipotermia severa ya que las cirugías que requieren hipotermia severa no han sido incluidas en el presente trabajo como los trasplantes cardíacos, cirugía del arco aórtico, aorta torácica, etc.

Un porcentaje importante de pacientes no requiere soporte de balón intraaórtico, aunque lo que si lo hacen son en una proporción significativa.

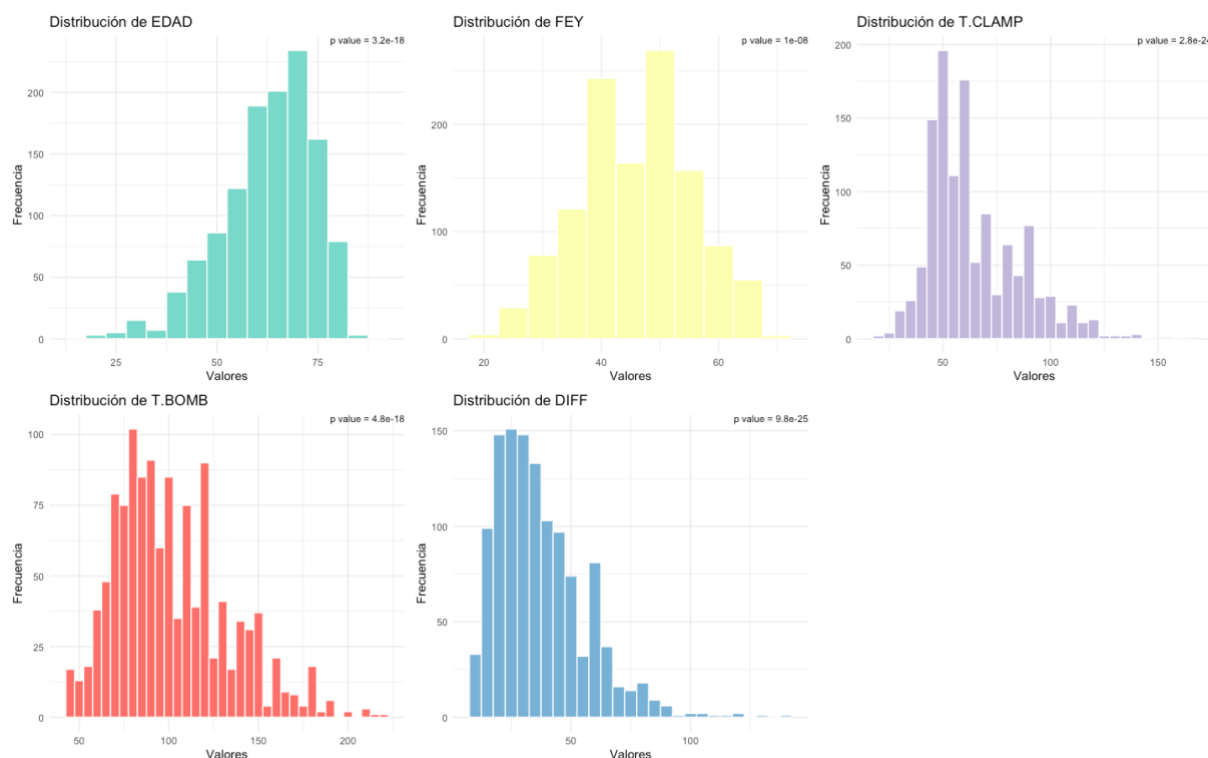


Figura 8: Distribución de las variables cuantitativas. 1 EDAD (P value $3.2e-18$). 2 FEY (P value $1e-08$). 3 T.CLAMP (P value $2.8e-24$). 4 T.BOMB (P value $4.8e-18$). 5 DIFF (P value $9.8e-25$). ELABORACION PROPIA.

En el análisis de las variables cuantitativas, se evaluaron las distribuciones de edad (EDAD), fracción de eyección (FEY), tiempo de clampeo aórtico (T.CLAMP), tiempo de bomba (T.BOMB) y la variable DIFF. A continuación, se presentan los principales hallazgos:

1. Edad (EDAD):

Los datos de edad muestran una distribución sesgada a la izquierda con una mayor concentración de individuos en el rango de 56 a 70 años. El rango observado va desde los 17 hasta los 88 años. La mediana es de 65 años. Shapiro-Wilk ($p = 3.2e-18$).

2. Fracción de Eyección (FEY):

La fracción de eyección tiene un rango entre 20 y 70%, con una mediana de 46%. La mayor concentración de pacientes se observa entre el 39% y 52%. Shapiro-Wilk ($p = 1e-08$).

3. Tiempo de Clampeo Aórtico (T.CLAMP):

Los tiempos de clampeo aórtico presentan una distribución que también se aparta de la normalidad, con un rango desde 20 hasta 165 minutos y una mediana de 60 minutos. Shapiro-Wilk ($p = 2.8e-24$).

4. Tiempo de Bomba (T.BOMB):

El tiempo de bomba varía entre 45 y 220 minutos, con una mediana de 95 minutos. Los valores se distribuyen principalmente entre los 80 y 120 minutos. Shapiro-Wilk ($p = 4.8e-18$).

5. DIFF (Variable Diferencia):

La variable DIFF presenta un rango entre 10 y 140, con una mediana de 35. La mayor concentración de observaciones se encuentra entre 25 y 46. Shapiro-Wilk ($p = 9.8e-25$).

Todas las variables cuantitativas fueron analizadas con el test de Shapiro-Wilk obteniéndose valores de significación ($P < 0.05$) por lo que se determina que ninguna de las variables tiene una distribución normal. Por ello se decide presentar en la siguiente tabla medidas no paramétricas como mediana, primer y tercer cuartil, valores máximos y mínimos. Los análisis estadísticos posteriores se realizarán con pruebas no paramétricas

	Min	1st.Qu.	Median	3rd.Qu	Max
EDAD	17	56	65	70	88
FEY	20	39	46	52	70
T.CLAMP	20	50	60	80	165
T.BOMB	45	80	95	120	220
DIFF	10	25	35	46	140

Tabla 4 : La tabla resumen de variables cuantitativas donde se muestra máximo, mínimo, mediana, 1º y 3º cuartil. Elaboración propia.

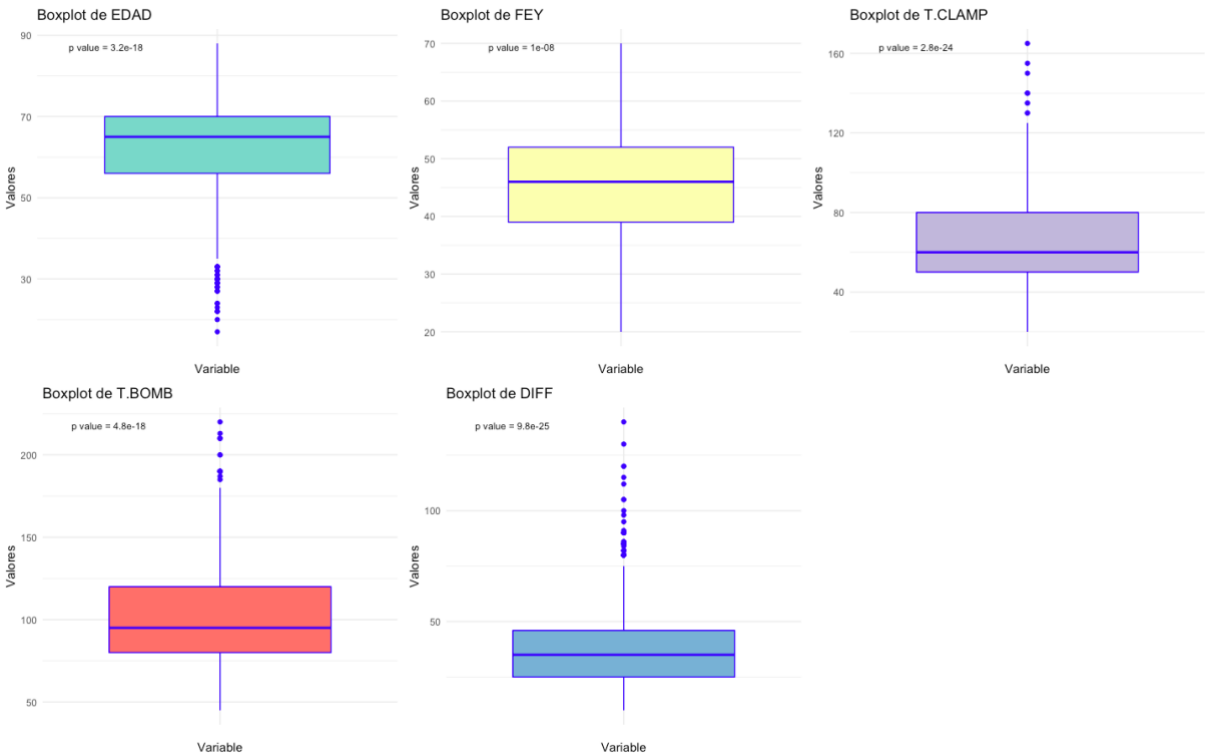


Figura 9: distribución de las variables cuantitativas. Boxplot para evaluación de outliers. 1 EDAD ($P \text{ value } 3.2e-18$). 2 FEY ($P \text{ value } 1e-08$). 3 T.CLAMP ($P \text{ value } 2.8e-24$). 4 T.BOMB ($P \text{ value } 4.8e-18$). 5 DIFF ($P \text{ value } 9.8e-25$). ELABORACION PROPIA.

Del análisis Boxplot de las variables cuantitativas edad, tiempo de clampeo, tiempo de bomba y diferencia se pueden identificar valores outliers ($n=87$). En el script del presente trabajo se realizó la visualización de los mismos creando un nuevo DataFrame

que identifica la primera columna como una variable cuantitativa donde se hayan dicho outliers.

```
> head(df_outliers)
```

```
# A tibble: 6 × 15
```

	Variable	SEX	EDAD	CIRUGIA	FEY	BYPASS	BYPASS.ARTERIALES	BYPASS.VENOSOS	VALVULA	POSICION	T.CLAMP	T.BOMB	HIPOT	BCIAO	DIFF
	<chr>	<fct>	<dbl>	<fct>	<dbl>	<fct>	<fct>	<fct>	<fct>	<fct>	<dbl>	<dbl>	<fct>	<fct>	<dbl>
1	DIFF	F	76	CRVAO	35	0	0	0	BIOLOGICO	AORTICO	53	135	LEVE	CON BCIAO	82
2	DIFF	M	77	CRM	30	3	1	2	NC	NC	50	135	LEVE	CON BCIAO	85
3	DIFF	M	55	CRM	26	3	1	2	NC	NC	51	137	LEVE	CON BCIAO	86
4	DIFF	F	71	CIV	30	3	1	2	NC	NC	60	140	MODERADA	CON BCIAO	80
5	DIFF	F	54	RAA	45	0	0	0	NC	NC	60	160	MODERADA	CON BCIAO	100
6	DIFF	M	55	BENTALL	20	0	0	0	MECANICO	AORTICO	68	180	MODERADA	CON BCIAO	112

Figura 10 : extracto de salida de R donde se visualizan los registros outliers, la primera columna "variable" indica a que variable cuantitativa corresponden dichos outliers.

PREOPERATORIO

ANÁLISIS BIVARIADO (PREOPERATORIO)

En el análisis bivariado se realizará la comparación de las variables tanto cuantitativas como cualitativas según la clasificación de los pacientes en los grupos con y sin BCIAO (Balón de Contrapulsación Intraaórtico).

BCIAO según SEXO

Para comparar BCIAO según sexo se utilizó el test de Chi Cuadrado bajo los supuestos de tamaño suficiente e independencia de la muestra, categoría mutuamente excluyente y tamaño esperado de valores mayor a 5 en el 80% de las celdas y ninguno igual a 0.




Figura 11 : Distribución de la variable BCIAO según sexo. Test de Chi Cuadrado de Pearson con corrección de continuidad de Yates (P value= 5.077e-11), Elaboración propia.

Dado que el p-valor es extremadamente bajo ($X^2 = 43.147$, $df = 1$, $p\text{-value} = 5.077e-11$) podemos rechazar la hipótesis nula de independencia entre las variables sexo (SEXO) y la variable BCIAO. Esto significa que hay una relación significativa entre estas dos variables. En este caso las mujeres requirieron mayormente BCIAO.

BCIAO según CIRUGIA

En este caso se intentó realizar test de Chi Cuadrado, pero al observar las frecuencias esperadas, algunas de ellas, son menores o próximas a 5 lo cual hace que las condiciones no se cumplan adecuadamente.

```
> print(chi_test_cirugia$expected)
```

	CON BCIAO	SIN BCIAO
BENTALL	10.580992	20.419008
BENTALL+CRM	5.802479	11.197521
CIA	5.119835	9.880165
CIV	2.730579	5.269421
COMBINADO	58.366116	112.633884
CRM	219.811570	424.188430
CRVAO	53.587603	103.412397
CRVAO+CRVM	19.114050	36.885950
CRVM	22.868595	44.131405
RAA	15.018182	28.981818

En estos casos se utiliza el test exacto de Fischer pero dado que la tabla es demasiado grande o tiene muchas combinaciones y el algoritmo puede encontrar dificultades al calcular todas las posibles distribuciones.

Para resolver este inconveniente se utilizó el test exacto de Fisher con simulación de Monte Carlo. El valor p fue calculado utilizando simulación, con un total de 100,000 réplicas. Esto es útil cuando el tamaño de la tabla es grande y no se pueden calcular exactamente todas las distribuciones posibles.




Figura 12 : Distribución de la variable BCIAO según CIRUGIA. Test de Fisher con simulación de Monte Carlo (P value= 1e-05), Elaboración propia.

El resultado de la prueba de Fisher con simulación de Monte Carlo indica que hay fuerte evidencia de asociación significativa (p-value = 1e-05) entre el tipo de cirugía y la variable BCIAO.




Figura 13 : Distribución de la variable BCIAO según VALVULA. Test de Chi Cuadrado de Pearson con corrección por continuidad de Yates (P value= 0.0004), Elaboración propia.

Para analizar la asociación entre el tipo de válvula (VALVULA) y la necesidad de BCIAO (BCIAO), se filtraron los datos eliminando aquellos casos en los que la válvula estaba etiquetada como "NC" (no corresponde), esta categoría fue creada para reemplazar los NA.

La prueba de Chi-cuadrado se realizó para verificar la independencia entre ambas variables. El resultado del test de Chi-cuadrado (X-squared = 12.46, df = 1, p-value = 0.0004158) indica que existe una asociación estadísticamente significativa entre el tipo de válvula y la necesidad de BCIAO, si bien esto puede sugerir que el tipo de válvula podría estar relacionado con la probabilidad de requerir BCIAO, es importante tener en cuenta que hay cirugías complejas como Bentall, Bentall+CRM y CRVAO+CRMV que tienen más probabilidad de requerir BCIAO y en su mayoría llevan válvulas mecánicas.

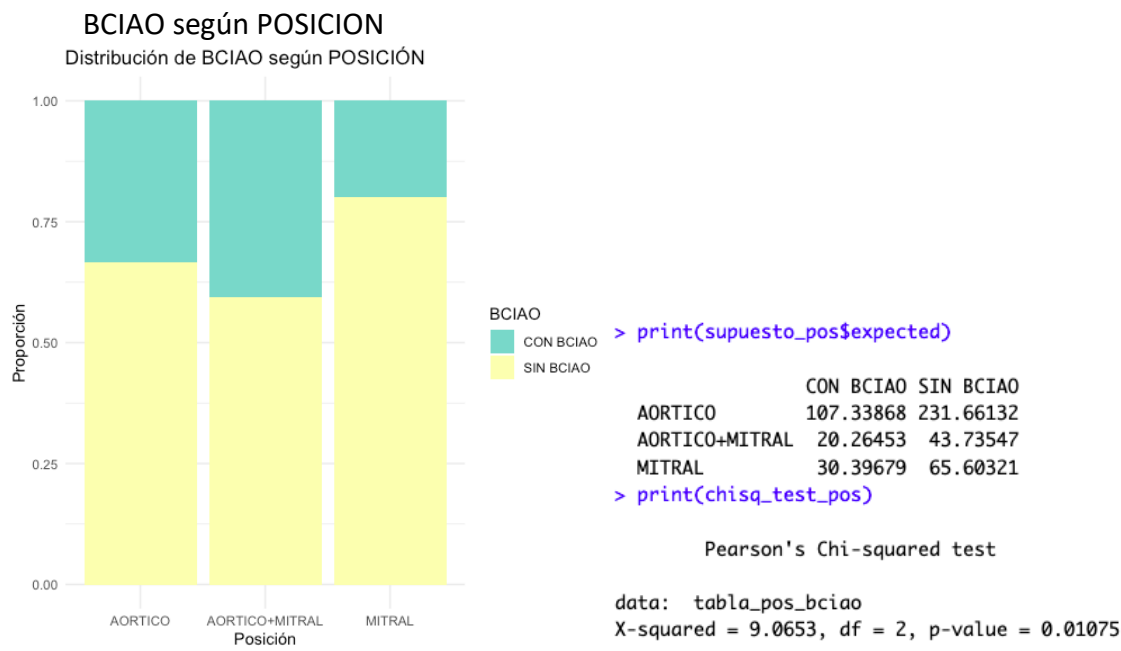


Figura 14 : Distribución de la variable BCIAO según POSICION. Test de Chi Cuadrado de Pearson (P value= 0.01075), Elaboración propia.

Se realizó un análisis para investigar la relación entre la posición de la válvula (POSICION) y la necesidad de BCIAO. Se filtraron los datos para eliminar las entradas donde POSICION era "NC", Los valores esperados de cada celda fueron mayores a 5, permitiendo el uso del test de Chi-cuadrado sin recurrir al test exacto de Fisher. El resultado del test de Chi-cuadrado (X-squared = 9.0653, df = 2, p-value = 0.01075) indica que existe una asociación estadísticamente significativa entre la posición de la válvula y la necesidad de BCIAO, lo que sugiere que la posición de la válvula puede influir en la probabilidad de requerir BCIAO.

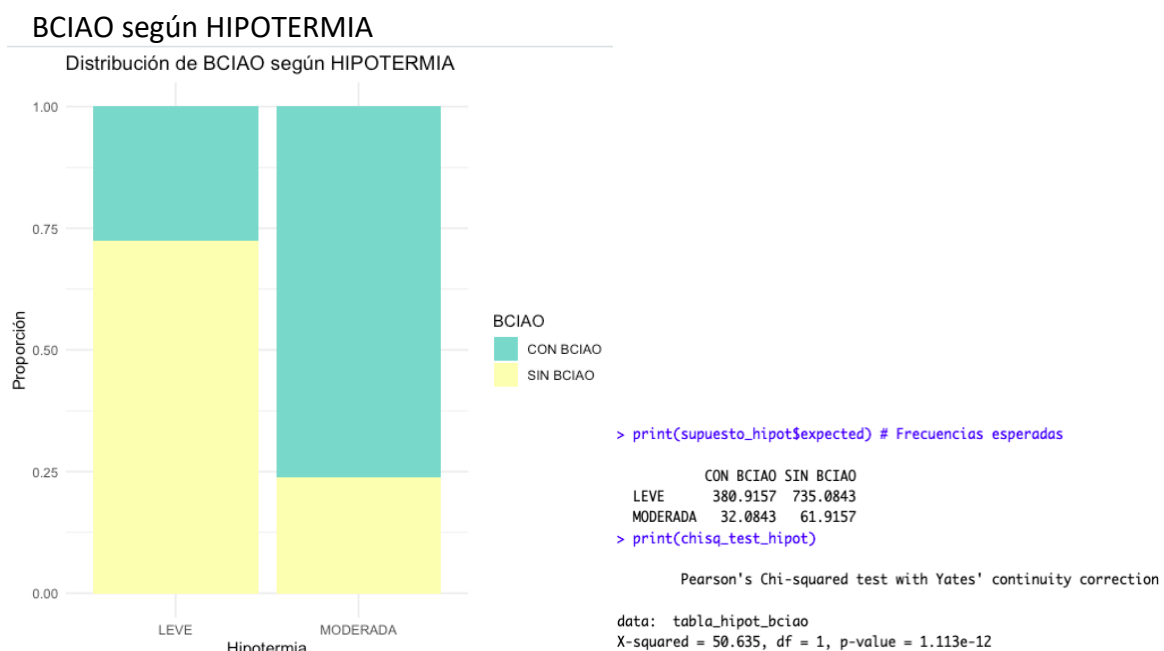


Figura 15 : Distribución de la variable BCIAO según HIPOTERMIA. Test de Chi Cuadrado de Pearson con corrección por continuidad de Yates (P value= 1.113e-12), Elaboración propia.

Se analizó la relación entre el grado de HIPOTERMIA y la necesidad de BCIAO. El resultado del test de Chi-cuadrado ($X^2 = 50.635$, $df = 1$, $p\text{-value} = 1.113e-12$) muestra una asociación estadísticamente significativa entre el grado de hipotermia y la necesidad de BCIAO, lo que sugiere una fuerte relación entre ambas variables. Esto es de suponer ya que las cirugías más complejas requieren temperatura corporal del paciente más bajas.

EDAD según BCIAO

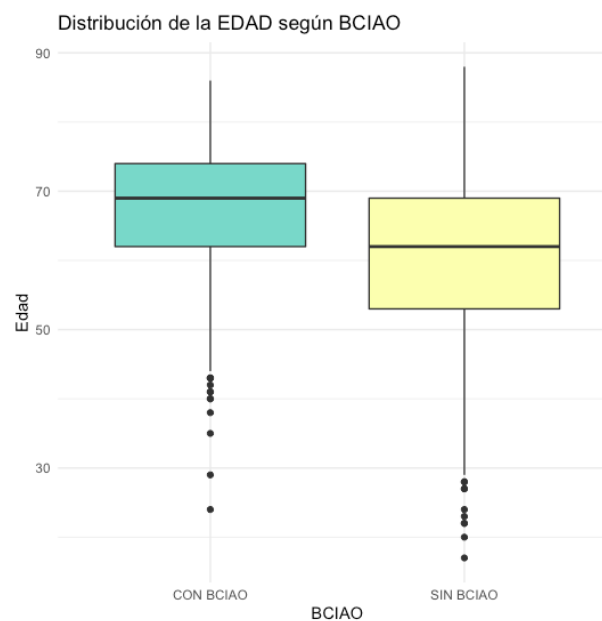


Figura 16 : Distribución de la variable BCIAO según EDAD. Wilcoxon rank-sum test ($P\text{ value} = 2.2e-16$), Elaboración propia.

El test U de Mann-Whitney o Wilcoxon rank-sum aplicado a la variable EDAD según el grupo BCIAO indica una diferencia estadísticamente significativa en la ubicación (mediana) entre los dos grupos ($P\text{ value} = 2.2e-16$). Esto sugiere que la edad de los pacientes en los grupos con y sin BCIAO difiere de manera significativa.

El intervalo de confianza del 95% para la diferencia en la ubicación está entre 5 y 8 años, con una diferencia estimada de 6 años entre los grupos. Esto implica que uno de los grupos tiende a ser consistentemente mayor en edad que el otro, lo que podría señalar una relación relevante entre la edad y la necesidad de BCIAO en los pacientes.

FEY según BCIAO




Figura 17 : Distribución de la variable FEY según BCIAO. Wilcoxon rank-sum test (P value= $2.2e-16$), Elaboración propia.

El resultado de la prueba de Wilcoxon rank-sum con corrección de continuidad para comparar la FEY (Fracción de Eyección) según el uso de BCIAO muestra un estadístico W de 35334 y un p-valor $< 2.2e-16$, indicando una diferencia estadísticamente significativa entre los grupos. El intervalo de confianza del 95% para la diferencia en la ubicación de las medianas se encuentra entre -14.00004 y -12.00001, y la estimación de la diferencia en la ubicación es de -13.00001. Esto sugiere que la mediana de FEY es menor en el grupo que utilizó BCIAO en comparación con el grupo que no lo hizo, implicando una menor fracción de eyección en pacientes con BCIAO.

DIFF según BCIAO

Se realizó la comparación entre la variable DIFF y BCIAO utilizando el Wilcoxon-Mann-Whitney entre la mediana de DIFF para los pacientes con balón y sin balón.

La variable DIFF es diferencia entre el tiempo de bomba y el tiempo de clampeo, representando una medida de dificultad para la salida de bomba, es de suponer que cuando mayor sea la variable DIFF mayor es la probabilidad de requerir BCIAO.

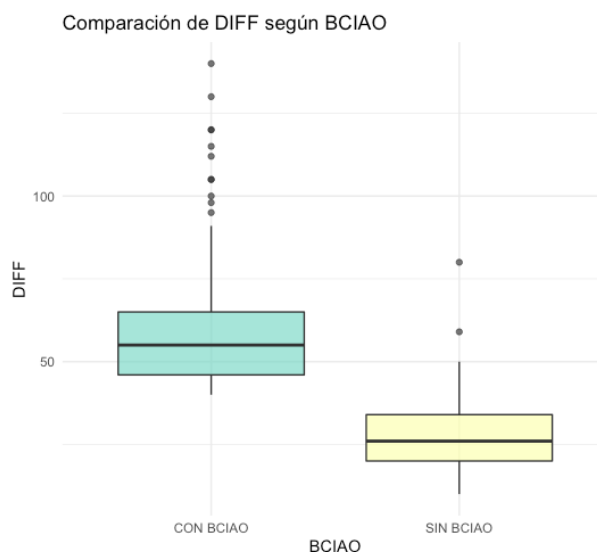


Figura 18 : Distribución de la variable DIFF según BCIAO. Test de Wilcoxon (P value= 2.2e-16), IC 95% (28 - 30). Elaboración propia.

Los resultados de la prueba de Wilcoxon sugieren que existe una diferencia significativa entre los grupos definidos por BCIAO en la variable DIFF, con un valor P value = 2.2e-16, lo que indica evidencia estadística muy fuerte para rechazar la hipótesis nula. La estimación de que la mediana de una de las muestras es 30 unidades mayor que la otra está respaldada por un IC 95% (28 - 30). Este intervalo proporciona un rango en el que es probable que se encuentre esta diferencia real.

TABLA RESUMEN BIVARIADO (VARIABLE/FEATURES CUALITATIVAS)

	CON BCIAO (N=413)	SIN BCIAO (N=797)	Total (N=1210)	p value
SEX				< 0.001
Femenino	185 (44.8%)	207 (26.0%)	392 (32.4%)	
Masculino	228 (55.2%)	590 (74.0%)	818 (67.6%)	
HIPOT				< 0.001
leve	349 (84.5%)	767 (96.2%)	1116 (92.2%)	
moderada	64 (15.5%)	30 (3.8%)	94 (7.8%)	
CIRUGIA				< 0.001
BENTALL	21 (5.1%)	10 (1.3%)	31 (2.6%)	
BENTALL+CRM	12 (2.9%)	5 (0.6%)	17 (1.4%)	
CIA	0 (0.0%)	15 (1.9%)	15 (1.2%)	
CIV	7 (1.7%)	1 (0.1%)	8 (0.7%)	
COMBINADO	79 (19.1%)	92 (11.5%)	171 (14.1%)	
CRM	223 (54.0%)	421 (52.8%)	644 (53.2%)	
CRVAO	22 (5.3%)	135 (16.9%)	157 (13.0%)	
CRVAO+CRVM	20 (4.8%)	36 (4.5%)	56 (4.6%)	
CRVM	4 (1.0%)	63 (7.9%)	67 (5.5%)	
RAA	25 (6.1%)	19 (2.4%)	44 (3.6%)	
	CON BCIAO (N=158)	SIN BCIAO (N=341)	Total (N=499)	p value
POSICION				0.011
AORTICO	113 (71.5%)	226 (66.3%)	339 (67.9%)	
AORTICO+MITRAL	26 (16.5%)	38 (11.1%)	64 (12.8%)	
MITRAL	19 (12.0%)	77 (22.6%)	96 (19.2%)	
VALVULA				< 0.001
BIOLOGICO	70 (44.3%)	95 (27.9%)	165 (33.1%)	
MECANICO	88 (55.7%)	246 (72.1%)	334 (66.9%)	

Tabla 5 : La tabla resumen que muestra la distribución de las diferentes variables/features categóricas en dos grupos de pacientes CON BCIAO y SIN BCIAO. Elaboración propia.

TABLA RESUMEN BIVARIADO (VARIABLES/FEATURES CUANTITATIVAS)

	CON BCIAO (N=413)	SIN BCIAO (N=797)	Total (N=1210)	p value
EDAD				< 0.001
Median	69	62	65	
IQR	12	16	14	
Range	24 - 86	17 - 88	17 - 88	
FEY				< 0.001
Median	38	50	46	
IQR	7	10	13	
Range	20 - 65	25 - 70	20 - 70	
T.CLAMP				< 0.001
Median	66	55	60	
IQR	33	22	30	
Range	35 - 130	20 - 165	20 - 165	
T.BOMB				< 0.001
Median	120	84	95	
IQR	41	30	40	
Range	75 - 220	45 - 190	45 - 220	
DIFF				< 0.001
Median	55	26	35	
IQR	19	14	21	
Range	40 - 140	10 - 80	10 - 140	

Tabla 6 : La tabla resumen que muestra la distribución de las diferentes variables/features cuantitativas en dos grupos de pacientes CON BCIAO y SIN BCIAO. Elaboración propia.

ANÁLISIS BIVARIADO (INTRAOPREOPERATORIO)

En el análisis bivariado se realizará la comparación de las variables tanto cuantitativas como cualitativas en relación con la variable dependiente continua DIFF para evaluar cómo se asocian con esta y determinar patrones o diferencias significativas en los datos.

Para evaluar la correlación entre las covariables EDAD, FEY y DIFF, se llevaron a cabo pruebas de normalidad de Shapiro-Wilk, que confirmaron que ninguna de las tres variables sigue una distribución normal (p -valor < 0.05 en todos los casos). Por lo tanto, se utilizó la correlación de Spearman para analizar las correlaciones bivariadas. Entre EDAD y FEY, se encontró una correlación negativa débil ($\rho = -0.24$, $p < 2.2e-16$), indicando que a mayor edad, hay una ligera tendencia a menores valores de FEY. La correlación entre EDAD y DIFF fue positiva y de magnitud moderada ($\rho = 0.27$, $p < 2.2e-16$), sugiriendo que los valores de DIFF aumentan ligeramente con la edad. La correlación más fuerte se observó entre FEY y DIFF, con un valor negativo de $\rho = -0.74$ ($p < 2.2e-16$), indicando una asociación inversa considerable entre ambas variables.

CORRELACIONES BIVARIADAS

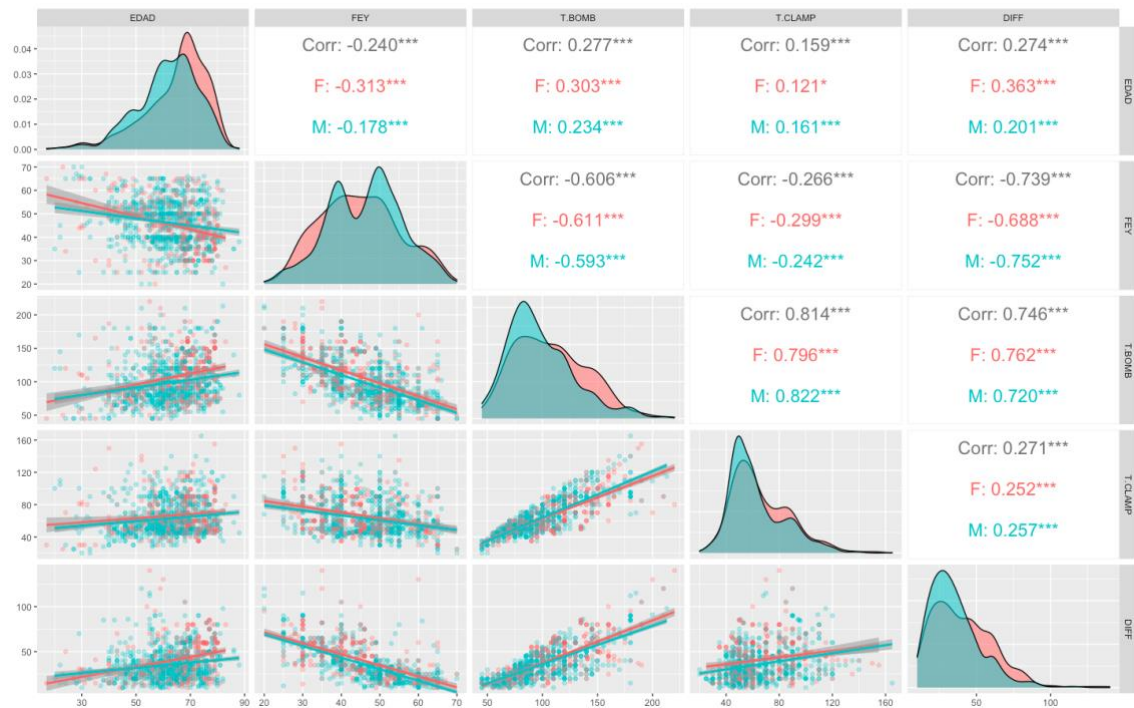


Figura 19 : Gráfico de Correlaciones Bivariadas. El coeficiente de correlación Rho se obtuvo a partir del test de Spearman dado que la distribución de las variables cuantitativas no fue normal. Elaboración propia.

Para analizar la distribución de DIFF según variables cuantitativas como EDAD y FEY se utilizó el modelo LOESS que es fundamental en el análisis de datos con distribuciones no paramétricas porque ofrece una forma flexible y robusta de modelar relaciones complejas sin asumir una forma específica de distribución. Esto permite que se puedan explorar y representar patrones no lineales y no uniformes en los datos.

DIFF según EDAD




Figura 20 : Gráfico de dispersión de DIFF según EDAD. Modelo LOESS. Elaboración propia.

la regresión LOESS se utilizó para modelar la relación entre EDAD (variable independiente) y DIFF (variable dependiente).

El parámetro span de 0.75 indica que el 75% de los puntos de datos en el vecindario de cada observación se utilizan para ajustar los modelos locales.

Grado degree = 2: Significa que los polinomios ajustados localmente son de grado 2 (cuadráticos).

Error estándar residual: 17.99, que indica la variabilidad de los errores del modelo.

La regresión LOESS se utilizó para capturar una relación no lineal entre EDAD y DIFF, y el modelo mostró un ajuste adecuado para analizar esta relación.

DIFF según FEY




Figura 21 : Gráfico de dispersión de DIFF según FEY. Modelo LOESS. Elaboración propia.

En este caso, se usó para evaluar cómo DIFF (variable dependiente) varía en función de FEY (variable independiente).

span = 0.75: Este valor indica que el 75% de los datos cercanos a cada punto son usados para ajustar los modelos locales

degree = 2: Los polinomios locales ajustados son de segundo grado, lo que permite capturar curvas más complejas en la relación.

El error estándar residual de 13.47 indica el promedio de la magnitud de los errores del modelo.

La correlación negativa significativa y el modelo LOESS muestran una relación no lineal entre FEY y DIFF, proporcionando un ajuste más detallado y flexible.

DIFF según SEXO




Figura 22 : Gráfico de Boxplot de DIFF según SEXO. One way Anova ($p\text{-value}=2.207e-06$) Wilcoxon rank test ($p\text{-value}=5.752e-06$). Elaboración propia.

La prueba de Levene se realizó para evaluar la homogeneidad de varianzas de la variable DIFF entre los grupos definidos por SEXO. Los resultados mostraron un estadístico F de 21.916 con un p-valor de $3.17e-06$, lo que indica una diferencia estadísticamente significativa en las varianzas ($p < 0.001$). Dado que las varianzas no son homogéneas, se optó por realizar un ANOVA de Welch, que no asume igualdad de varianzas y es más robusto en estas condiciones. El ANOVA de Welch arrojó un estadístico F de 22.807, con grados de libertad del denominador de 661.27 y un p-valor de $2.207e-06$, indicando una diferencia significativa entre las medias de DIFF según SEXO.

La prueba de Wilcoxon rank sum se utilizó como alternativa no paramétrica para comparar las distribuciones de DIFF entre los grupos de SEXO, especialmente útil cuando los supuestos de normalidad no se cumplen. Los resultados mostraron un estadístico W de 186082 y un p-valor de $5.751e-06$, indicando una diferencia significativa en la ubicación de las distribuciones ($p < 0.001$). Esto sugiere que las medianas de DIFF entre los grupos de SEXO son diferentes.

DIFF según CIRUGIA

```
> leveneTest(DIFF ~ CIRUGIA, data = datos)
Levene's Test for Homogeneity of Variance (center = median)
      Df F value    Pr(>F)
group   9 19.127 < 2.2e-16 ***
1200
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Para realizar ANOVA se utilizó la prueba de Levene que evalúa el supuesto de homogeneidad de las varianzas de DIFF entre los distintos grupos de CIRUGIA. El resultado mostró un estadístico F de 19.127 y un p-valor menor a $2.2e-16$, indicando

una diferencia estadísticamente significativa en las varianzas ($p < 0.001$). Esto implica que el supuesto de homocedasticidad no se cumple.

```
> oneway.test(DIFF ~ CIRUGIA, data = datos, var.equal = FALSE)

One-way analysis of means (not assuming equal variances)

data:  DIFF and CIRUGIA
F = 37.104, num df = 9.000, denom df = 92.615, p-value < 2.2e-16
```

Debido a que la prueba de Levene mostró que las varianzas no son homogéneas, se realizó un ANOVA de Welch, que es más robusto y no asume igualdad de varianzas. El resultado fue un estadístico F de 37.104 con grados de libertad del denominador de 92.615 y un p-valor menor a $2.2e-16$, indicando diferencias significativas en las medias de DIFF entre los grupos de CIRUGIA.




Figura 23 : Gráfico de Boxplot de DIFF según CIRUGIA. One way Anova ($p\text{-value}=2.2e-16$). Elaboración propia.

La comparación entre pares se realizó con el ajuste de Bonferroni, que no depende de la homogeneidad de varianzas, resulta más adecuado para garantizar un control más estricto del error tipo I. Este método utiliza una prueba t de pares para comparar todas las combinaciones posibles de medias de DIFF entre los grupos de CIRUGIA. La tabla muestra los p-valores de estas comparaciones.

Resultados del Test de Comparación Múltiple (Bonferroni)									
	BENTALL	BENTALL+CRM	CIA	CIV	COMBINADO	CRM	CRVAO	CRVAO+CRVM	CRVM
BENTALL+CRM	1.000000	NA	NA	NA	NA	NA	NA	NA	NA
CIA	0.000005	0.000510	NA	NA	NA	NA	NA	NA	NA
CIV	1.000000	1.000000	0.0063459	NA	NA	NA	NA	NA	NA
COMBINADO	0.0114552	0.5961901	0.0000000	0.4318965	NA	NA	NA	NA	NA
CRM	0.0006122	0.0367134	0.0000001	0.1212297	0.0063370	NA	NA	NA	NA
CRVAO	0.0000098	0.0007499	0.0278444	0.0201827	0.0000000	0.0000000	NA	NA	NA
CRVAO+CRVM	0.0004837	0.0279067	0.0000008	0.0847952	0.1522558	1.0000000	0.0148798	NA	NA
CRVM	0.0000033	0.0002879	0.8459326	0.0138740	0.0000000	0.0000000	1.0000000	0.0001351	NA
RAA	1.0000000	1.0000000	0.0000000	1.0000000	0.9020711	0.0050766	0.0000016	0.0064601	1e-07

Figura 24 : Comparación por pares con método de Bonferroni. Elaboración propia.

DIFF según VALVULA

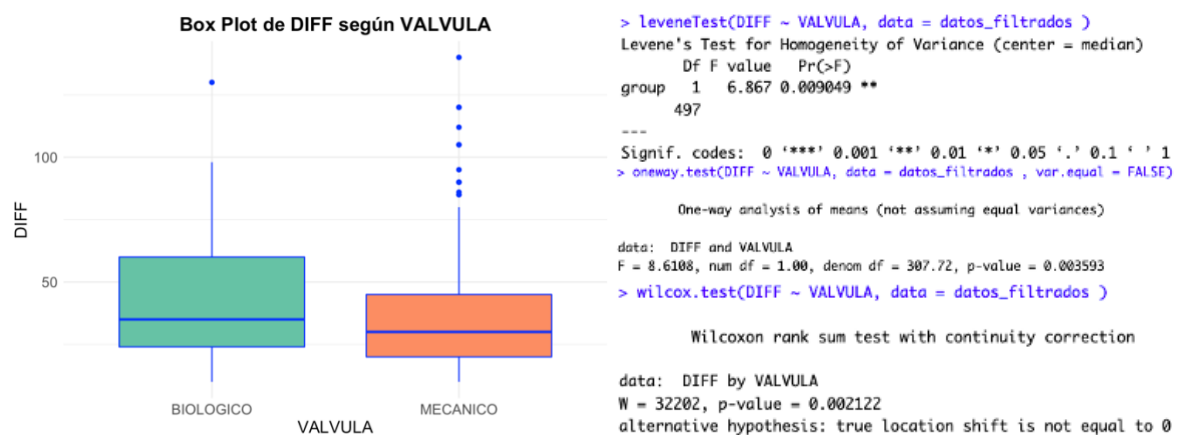


Figura 25 : Gráfico de Boxplot de DIFF según VALVULA. One way Anova ($p\text{-value}=0.0036$). Wilcoxon rank test ($p\text{-value}=0.002122$). Elaboración propia.

El test de Levene se utilizó para evaluar la homogeneidad de las varianzas en la variable DIFF entre los grupos definidos por VALVULA. Los resultados mostraron que la prueba fue significativa ($F = 6.867$, $p = 0.009049$), lo que sugiere que las varianzas entre los grupos no son iguales. Dado que el supuesto de homocedasticidad no se cumplió, se realizó un ANOVA de Welch.

El resultado del ANOVA de Welch ($F = 8.6108$, $p = 0.003593$) indicó una diferencia significativa en las medias de DIFF entre los grupos de VALVULA.

Además, dado que la distribución de la variable DIFF no es normal, se aplicó la prueba de Wilcoxon para comparar las medianas entre los grupos. Los resultados de esta prueba no paramétrica mostraron una diferencia significativa ($W = 32202$, $p = 0.002122$), lo que respalda la hipótesis de que hay una diferencia significativa en la tendencia central de DIFF entre los grupos de VALVULA. Esto refuerza la conclusión de que las diferencias observadas no se deben al azar.

DIFF según POSICION

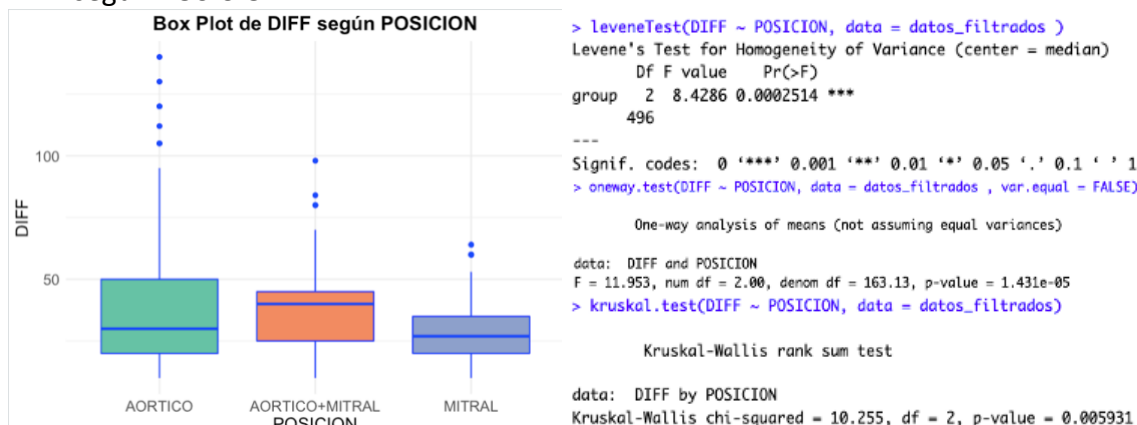


Figura 26 : Gráfico de Boxplot de DIFF según POSICION. One way Anova ($p\text{-value}=1.431e-05$). Wilcoxon rank test ($p\text{-value}=0.005931$). Elaboración propia.

El test Levene para la variable DIFF entre los grupos definidos por POSICION mostró resultados significativos ($F = 8.4286$, $p = 0.0002514$), indicando que las varianzas no son homogéneas entre los grupos. Debido a esta violación del supuesto de homocedasticidad, se llevó a cabo un ANOVA de Welch, que es adecuado para situaciones en las que las varianzas no son iguales. El ANOVA de Welch resultó significativo ($F = 11.953$, $p = 1.431e-05$), lo que sugiere diferencias en las medias de DIFF entre las distintas posiciones analizadas.

Para identificar qué grupos específicos presentaban diferencias significativas, se realizó una prueba t de comparaciones múltiples ajustada por Bonferroni. Se muestra tabla a continuación.

Resultados del Test de Comparación Múltiple (Bonferroni)		
	AORTICO	AORTICO+MITRAL
AORTICO+MITRAL	1.00e+00	NA
MITRAL	4.02e-05	0.0016124

Además, se efectuó un test de Kruskal-Wallis, una prueba no paramétrica que confirmó la existencia de diferencias significativas entre los grupos de POSICION (chi-cuadrado = 10.255, $p = 0.005931$), apoyando los resultados previos y reforzando la evidencia de que la tendencia central de DIFF varía según la POSICION.

DIFF según HIPOTERMIA

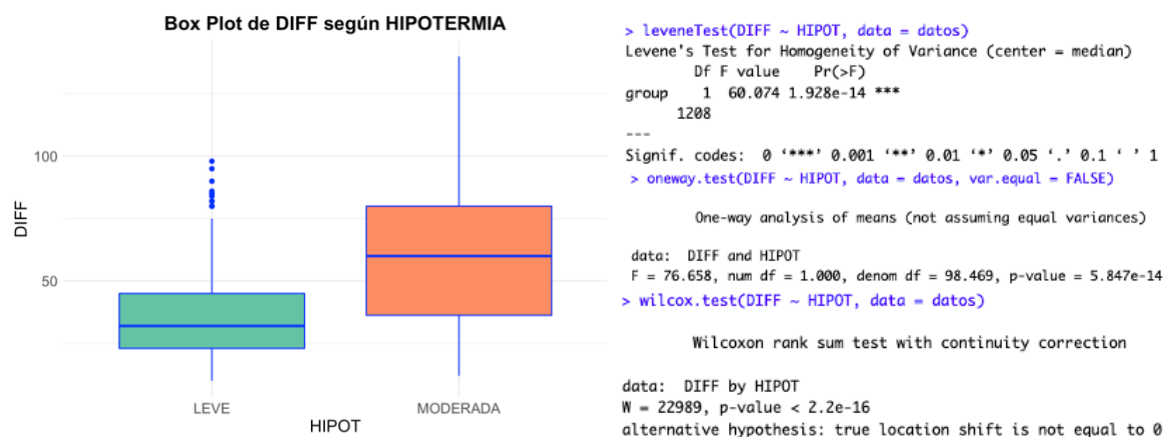


Figura 27 : Gráfico de Boxplot de DIFF según HIPOTERMIA. One way Anova ($p\text{-value}=5.847e-15$). Wilcoxon rank test ($p\text{-value}=2.2e-16$). Elaboración propia.

El test de Levene realizado para la variable DIFF en función de la variable HIPOTERMIA (HIPOT) mostró un resultado altamente significativo ($F = 60.074$, $p = 1.928e-14$), indicando que las varianzas entre los grupos no son homogéneas. Este hallazgo viola el supuesto de homocedasticidad necesario para un ANOVA tradicional. Para ajustar este análisis, se llevó a cabo un ANOVA de Welch, que es más adecuado en escenarios donde las varianzas son desiguales. Los resultados del ANOVA de Welch también fueron altamente significativos ($F = 76.658$, $p = 5.847e-14$), sugiriendo que hay diferencias en las medias de DIFF entre los grupos de HIPOTERMIA.

Dado que la variable DIFF no sigue una distribución normal, se aplicó una prueba de Wilcoxon (test de suma de rangos de Wilcoxon) para confirmar las diferencias entre los grupos de HIPOTERMIA. Esta prueba no paramétrica también resultó significativa ($W = 22989$, $p < 2.2e-16$), reforzando la conclusión de que la mediana de DIFF varía de manera significativa según las categorías de HIPOTERMIA.

PREOPERATORIO

RED NEURONAL

Para balancear el conjunto de datos, se seleccionan aleatoriamente 413 filas del subset "SIN BCIAO" (undersampling), garantizando que el conjunto resultante tenga igual número de casos para ambas categorías. Finalmente, se combinan ambos subsets en un nuevo dataframe datos1 y se verifica que contenga 826 filas, con 413 en cada categoría de BCIAO. Esto asegura que el análisis posterior no esté sesgado por una desproporción en las clases.

En este análisis de datos en R, se particionó el conjunto de datos en una proporción de 70% para entrenamiento y 30% para el testeo, utilizando una semilla de 27848992 para mantener la reproducibilidad. Después de confirmar que no hay valores nulos en el conjunto de entrenamiento, se convirtió la variable de respuesta BCIAO a un factor. El conjunto de entrenamiento resultante contiene 580 observaciones y el de prueba 246. En ambas particiones, la proporción de clases para BCIAO (CON y SIN BCIAO) se mantuvo muy cercana al 70/30 original, asegurando una distribución balanceada y representativa entre las clases en ambos conjuntos.

Entrenamiento del modelo

Se configuró una cuadrícula de hiperparámetros para ajustar una red neuronal, variando el número de neuronas en la capa oculta (size) entre 1, 3 y 5, y los valores de regularización L2 (decay) entre 0, 0.01, 0.1 y 0.0001, generando un total de 12 combinaciones.

Se utilizó validación cruzada de 5 particiones (5-fold) para evaluar los modelos. El proceso resultó en un valor final de pérdida de 178.563851 y alcanzó la convergencia de manera satisfactoria.

```
> print(red_cv) # Resumen del modelo entrenado
Neural Network
```

```
580 samples
7 predictor
2 classes: 'CON BCIAO', 'SIN BCIAO'
```

```
No pre-processing
Resampling: Cross-Validated (5 fold)
Summary of sample sizes: 464, 464, 464, 464, 464
Resampling results across tuning parameters:
```

size	decay	Accuracy	Kappa
1	0e+00	0.5758621	0.1517241
1	1e-04	0.6379310	0.2758621
1	1e-02	0.8551724	0.7103448
1	1e-01	0.7758621	0.5517241
3	0e+00	0.6258621	0.2517241
3	1e-04	0.6517241	0.3034483
3	1e-02	0.8517241	0.7034483
3	1e-01	0.8482759	0.6965517
5	0e+00	0.7724138	0.5448276
5	1e-04	0.7017241	0.4034483
5	1e-02	0.8517241	0.7034483
5	1e-01	0.8603448	0.7206897

```
Accuracy was used to select the optimal model using the largest value.
The final values used for the model were size = 5 and decay = 0.1.
```

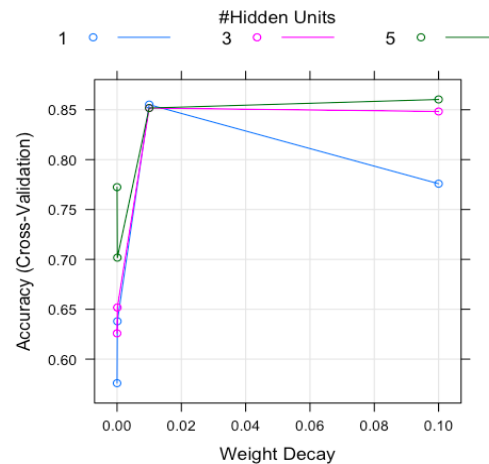


Figura 28 : Gráfico de rendimiento del modelo que muestra la precisión alcanzada por cada combinación de hiperparámetros probada. Elaboración propia.

Este modelo de red neuronal entrenado con validación cruzada utilizó 580 muestras y 7 predictores para clasificar en dos clases: "CON BCIAO" y "SIN BCIAO". En el proceso de ajuste, se probaron varios valores de los hiperparámetros size (número de neuronas en la capa oculta) y decay (tasa de regularización L2 para evitar overfitting).

Rendimiento del modelo

Los resultados mostraron que los valores de Accuracy y el índice Kappa (medida de acuerdo entre las clases) variaron según los hiperparámetros, siendo la mejor combinación size = 5 y decay = 0.1, que logró un Accuracy del 0.8415. IC 95% (0.7897, 0.8848) y un Kappa de 0.6829 indicando un desempeño robusto en la clasificación de las clases.

```
> matriz_default
Confusion Matrix and Statistics

              Reference
Prediction   CON BCIAO SIN BCIAO
CON BCIAO      109      25
SIN BCIAO       14      98

      Accuracy : 0.8415
      95% CI   : (0.7897, 0.8848)
No Information Rate : 0.5
P-Value [Acc > NIR] : <2e-16

      Kappa : 0.6829

McNemar's Test P-Value : 0.1093

      Sensitivity : 0.8862
      Specificity : 0.7967
      Pos Pred Value : 0.8134
      Neg Pred Value : 0.8750
      Prevalence : 0.5000
      Detection Rate : 0.4431
      Detection Prevalence : 0.5447
      Balanced Accuracy : 0.8415

      'Positive' Class : CON BCIAO
```

Figura 29 : Matriz de confusión y métricas. Obtenido por defecto con umbral/threshold = 0.5. Elaboración propia

Se usó la función plotnet para representar la arquitectura de la red, esta visualización facilita la interpretación de la estructura del modelo y de las conexiones que podrían ser relevantes para la clasificación de las clases 'CON BCIAO' y 'SIN BCIAO'.




Figura 30 : Gráfico de arquitectura de la red, mostrando la estructura de la red neuronal con conexiones y sesgos, lo que ayuda a visualizar cómo se distribuyen los pesos sinápticos y la configuración de las capas

Área bajo la curva (AUC)

El modelo de red neuronal generó probabilidades de predicción para la clase 'CON BCIAO' en el conjunto de prueba. Posteriormente, se calculó la curva ROC y el AUC (Área Bajo la Curva) para medir la capacidad del modelo de discriminar correctamente entre las clases, resultando en un AUC de 0.8876, lo cual indica un alto poder de predicción. El intervalo de confianza (IC) del 95% para el AUC se ubicó entre 0.8441-0.931 (método de DeLong), validando la precisión del modelo con un margen de confianza adecuado.




Figura 31 : Gráfico de la curva ROC, mostrando la sensibilidad frente a 1 - especificidad, con un área sombreada bajo la curva para resaltar el desempeño del modelo. La línea diagonal de referencia también permite comparar el modelo con una predicción aleatoria, ayudando a visualizar la efectividad en la clasificación de la clase positiva 'CON BCIAO'.

Matriz optimizada

Se calculó un umbral óptimo de 0.5645416 en la curva ROC, balanceando sensibilidad y especificidad para mejorar la clasificación de la clase positiva 'CON BCIAO'. Al aplicar este umbral, la matriz de confusión mostró una precisión global de 0.8415 (IC del 95%: 0.7897, 0.8848) y un índice Kappa de 0.6829, indicando una concordancia sustancial, ambos valores son iguales a la matriz previa que tiene un umbral por default de 0.5.

La sensibilidad fue del 0.8618 y la especificidad del 0.8211, lo que implica que el modelo identifica correctamente la mayoría de los casos 'CON BCIAO' y 'SIN BCIAO' en el conjunto de prueba. Observándose mejora en la especificidad con umbral óptimo.

```
> matriz_optima
Confusion Matrix and Statistics

      Reference
Prediction CON BCIAO SIN BCIAO
CON BCIAO    106     22
SIN BCIAO     17    101

    Accuracy : 0.8415
    95% CI : (0.7897, 0.8848)
  No Information Rate : 0.5
  P-Value [Acc > NIR] : <2e-16

    Kappa : 0.6829

  McNemar's Test P-Value : 0.5218

    Sensitivity : 0.8618
    Specificity : 0.8211
   Pos Pred Value : 0.8281
   Neg Pred Value : 0.8559
    Prevalence : 0.5000
  Detection Rate : 0.4309
Detection Prevalence : 0.5203
  Balanced Accuracy : 0.8415

'Positive' Class : CON BCIAO

> threshold <- optimal_threshold
> threshold
[1] 0.5645416
```

Figura 32 : Matriz de confusión y métricas. Obtenido por defecto con umbral/threshold óptimo = 0.5645416. Elaboración propia

Se calculo el F1 Score = 0.8446215, lo que indica un buen equilibrio entre precisión y sensibilidad. Este valor es especialmente útil en problemas de clasificación desequilibrados, ya que proporciona una única métrica que resume la capacidad del modelo para clasificar correctamente tanto las clases positivas como las negativas.

Métrica	Matriz Default	Matriz Óptima
Accuracy	0.8415	0.8415
95% CI	(0.7897, 0.8848)	(0.7897, 0.8848)
Kappa	0.6829	0.6829
McNemar's Test P-Value	0.1093	0.5218
Sensitivity	0.8862	0.8618
Specificity	0.7967	0.8211
Pos Pred Value (PPV)	0.8134	0.8281
Neg Pred Value (NPV)	0.8750	0.8559
Prevalence	0.5000	0.5000
Detection Rate	0.4431	0.4309

Detection Prevalence	0.5447	0.5203
Balanced Accuracy	0.8415	0.8415
F1 Score	0.8482	0.8446

Tabla 7 : Comparación de matrices (umbral default 0.5 vs umbral optimizado 0.5645). *Elaboración propia*

La matriz óptima ofrece la misma precisión general, mayor especificidad, además de un p-valor de McNemar más alto, lo que indica un balance de errores más uniforme entre clases. En conjunto, estas métricas indican que el modelo óptimo tiene un rendimiento similar en términos de balance y precisión general.

Posteriormente se llevó a cabo un análisis exhaustivo y visualización de métricas de rendimiento del modelo en función de diferentes umbrales de clasificación. Se utilizó la predicción de las probabilidades de la clase "CON BCIAO" para el conjunto de testeo y se creó una secuencia de umbrales que varía de 0 a 1. Para cada umbral, se calcularon las métricas clave como sensibilidad, especificidad, precisión, tasa de acierto y F1 Score, utilizando una matriz de confusión generada a partir de las predicciones binarizadas.

Este enfoque permite observar cómo las métricas cambian a medida que se ajusta el umbral, facilitando la identificación del punto óptimo que maximiza la sensibilidad y la especificidad, lo que es crucial para mejorar la toma de decisiones en la clasificación de eventos.

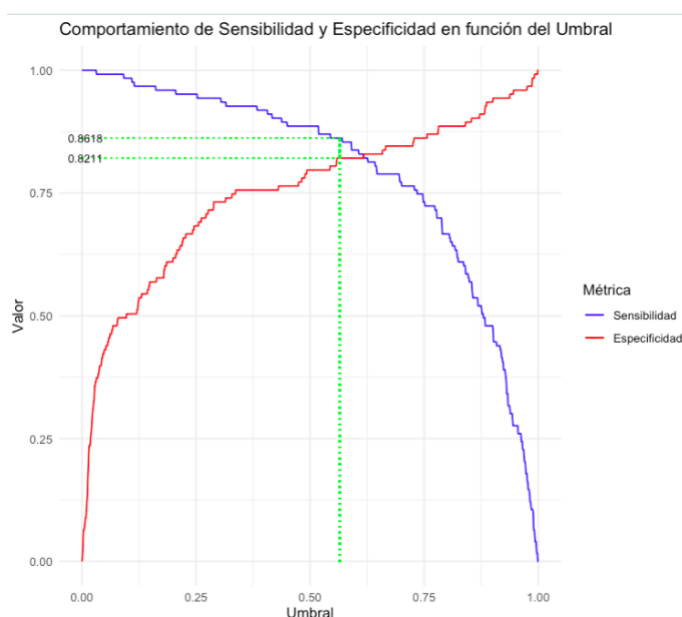


Figura 33 : Gráfico de comportamiento de Sensibilidad y Especificidad en función del Umbral. La línea verde indica en valor de umbral optimo (Threshold = 0.5645416) calculado a partir del AUC y su correspondiente Sensibilidad y Especificidad




Figura 34 : Gráfico de métricas de rendimiento en función del Umbral. Se incluye Sensibilidad, Especificidad, tasa de Acierto (Accuracy), Precisión y F1 Score. La línea verde indica en valor de umbral óptimo (Threshold = 0.5645416) calculado a partir del AUC Elaboración propia.

Se utilizaron las predicciones sobre el grupo de testeo utilizando el modelo de red neuronal previamente entrenado (almacenado en `red_cv`). Primero, se obtienen las probabilidades de pertenencia a la clase "CON BCIAO" y se almacenan junto con las etiquetas reales en un dataframe llamado `predicciones`. A continuación, se inicializa un dataframe vacío para almacenar métricas de rendimiento del modelo a diferentes umbrales de clasificación, incluyendo sensibilidad, especificidad, tasa de acierto, tasa de error, precisión y F1 Score.

Luego, se itera sobre una secuencia de umbrales entre 0.1 y 0.75, donde para cada umbral se generan predicciones clasificadas y se construye una matriz de confusión. Los valores de verdaderos positivos (VP), falsos negativos (FN), verdaderos negativos (VN) y falsos positivos (FP) se extraen de la matriz de confusión, y se calculan las métricas correspondientes. Los resultados se almacenan en el dataframe `resultados`. Finalmente, se imprime el dataframe con todas las métricas y se filtran los resultados para mostrar únicamente aquellos que se encuentran en un rango específico de interés que incluye al umbral óptimo.

```
> print(rango_resultados)
```

	umbral	sensibilidad	especificidad	FP	FN	tasa_acierto	tasa_error	precision	F1_score
4001	0.5000	0.8617886	0.8211382	14	25	0.8414634	0.1585366	0.828125	0.8446215
4002	0.5001	0.8617886	0.8211382	14	25	0.8414634	0.1585366	0.828125	0.8446215
4003	0.5002	0.8617886	0.8211382	14	25	0.8414634	0.1585366	0.828125	0.8446215
4004	0.5003	0.8617886	0.8211382	14	25	0.8414634	0.1585366	0.828125	0.8446215
4005	0.5004	0.8617886	0.8211382	14	25	0.8414634	0.1585366	0.828125	0.8446215

4643	0.5642	0.8617886	0.8211382	17	22	0.8414634	0.1585366	0.828125	0.8446215
4644	0.5643	0.8617886	0.8211382	17	22	0.8414634	0.1585366	0.828125	0.8446215
4645	0.5644	0.8617886	0.8211382	17	22	0.8414634	0.1585366	0.828125	0.8446215
4646	0.5645	0.8617886	0.8211382	17	22	0.8414634	0.1585366	0.828125	0.8446215
4647	0.5646	0.8617886	0.8211382	17	22	0.8414634	0.1585366	0.828125	0.8446215
4648	0.5647	0.8617886	0.8211382	17	22	0.8414634	0.1585366	0.828125	0.8446215
4649	0.5648	0.8617886	0.8211382	17	22	0.8414634	0.1585366	0.828125	0.8446215

Figura 35 : Extracto de R de métricas de rendimiento en secuenciación de umbrales entre 0.50 y 0.57
Se incluye Sensibilidad, Especificidad, FP, FN, tasa de Acierto (Accuracy), Tasa de Error, Precisión y F1 Score. En celeste se identifica el umbral optimo obtenido del AUC. Elaboración propia.

SUPPORT VECTOR MACHINE (SVM)

Se generó una Máquinas de Vectores de Soporte (SVM) con kernel de función radial (RBF) para predecir la variable BCIAO, que indica si se utilizó un balón de contrapulsación intraaórtico. Posteriormente, se dividieron los datos, del subset previamente balanceado, en conjuntos de entrenamiento (70%) y prueba (30%) usando createData Partition y se definieron los grupos de entrenamiento y testeo con las variables predictoras relevantes (SEX, FEY, EDAD, CIRUGIA, VALVULA, POSICION, HIPOT).

Entrenamiento del modelo

Se configuró una cuadrícula de hiperparámetros para ajustar un modelo SVM (Support Vector Machine) con kernel de base radial, variando los valores de C (parámetro de regularización) entre 0.1, 1, 10 y 100, y los valores de sigma (parámetro del kernel radial) entre 0.01, 0.1 y 1, generando un total de 12 combinaciones.

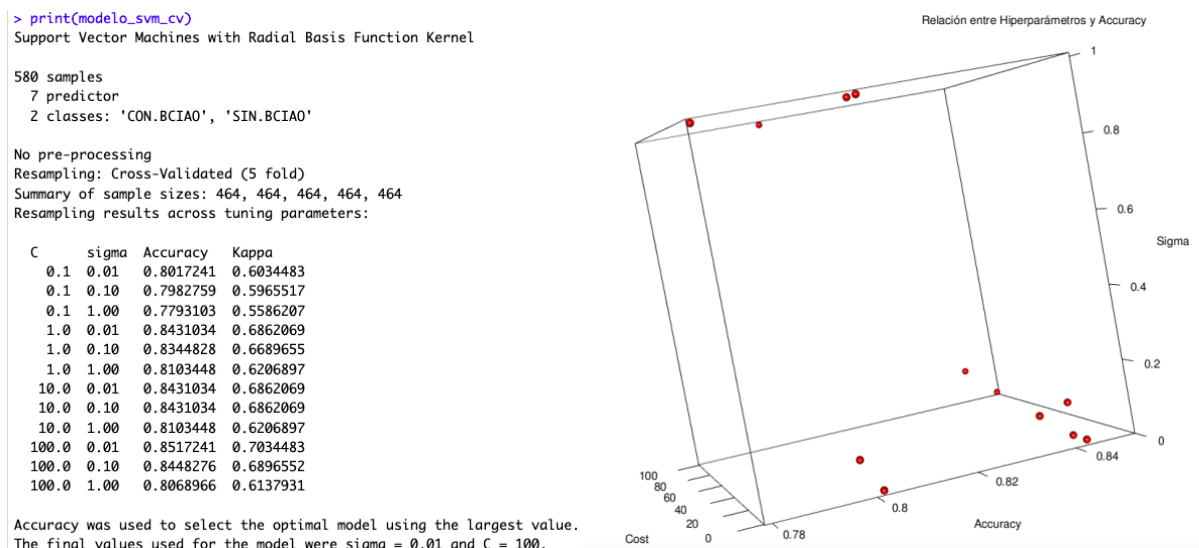


Figura 36 : Gráfico de rendimiento del modelo que muestra el accuracy alcanzado por cada combinación de hiperparámetros probada. Elaboración propia.

Se utilizó validación cruzada de 5 particiones (5-fold) para evaluar los modelos, garantizando que cada partición tuviera 464 muestras de entrenamiento en cada iteración. Este modelo SVM entrenado con validación cruzada utilizó 580 muestras y

siete predictores para clasificar en dos clases: 'CON.BCIAO' y 'SIN.BCIAO'. En el proceso de ajuste, se probaron varias combinaciones de los hiperparámetros C y sigma para encontrar el mejor rendimiento en términos de precisión (Accuracy).

La mejor combinación se seleccionó en función del valor más alto de Accuracy, y resultó ser C = 100 y sigma = 0.01, con una precisión de 0.8517 y un Kappa de 0.7034. Estos resultados indican que el modelo entrenado tuvo un buen desempeño en la clasificación de los datos y su capacidad para distinguir entre los dos grupos de BCIAO fue robusta, especialmente con el uso de un C alto y una sigma bajo, lo cual controla el margen de clasificación y la regularización del modelo.

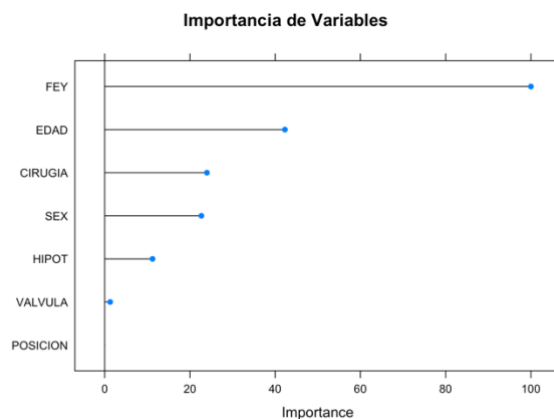


Figura 37 : Gráfico de importancia de cada variable en el modelo. Elaboración propia

Rendimiento del modelo

Al evaluar el rendimiento del modelo en el grupo de testeo con los hiperparámetros C = 100 y sigma = 0.01 se obtienen las siguientes métricas:

```
> print(matriz_confusion_svm)
Confusion Matrix and Statistics

              Reference
Prediction   CON.BCIAO SIN.BCIAO
CON.BCIAO      106      26
SIN.BCIAO       17      97

      Accuracy : 0.8252
      95% CI   : (0.7719, 0.8705)
    No Information Rate : 0.5
      P-Value [Acc > NIR] : <2e-16

              Kappa : 0.6504

  McNemar's Test P-Value : 0.2225

      Sensitivity : 0.8618
      Specificity : 0.7886
    Pos Pred Value : 0.8030
    Neg Pred Value : 0.8509
      Prevalence : 0.5000
    Detection Rate : 0.4309
  Detection Prevalence : 0.5366
    Balanced Accuracy : 0.8252

      'Positive' Class : CON.BCIAO
```

Figura 38 : Matriz de confusión y métricas. Elaboración propia

El valor de F1-score, que es una medida de equilibrio entre la precisión y la sensibilidad, se calculó como 0.8314. Este puntaje indica que el modelo tiene un buen equilibrio entre

la capacidad de identificar correctamente los casos positivos y minimizar las predicciones incorrectas, lo que es útil cuando las clases tienen un costo de error diferente o cuando se busca un rendimiento robusto en ambos tipos de error.

Área bajo la curva (AUC)




Figura 39: Gráfico de la curva ROC, mostrando la sensibilidad frente a 1 - especificidad, con un área sombreada bajo la curva para resaltar el desempeño del modelo. La línea diagonal de referencia también permite comparar el modelo con una predicción aleatoria, ayudando a visualizar la efectividad en la clasificación de la clase positiva 'CON BCIAO'.

Se calculó la curva ROC (Receiver Operating Characteristic) y el AUC (Área Bajo la Curva) para evaluar la capacidad del modelo de discriminar correctamente entre las clases 'CON.BCIAO' y 'SIN.BCIAO'. El AUC obtenido fue de 0.8805, lo que indica un buen desempeño del modelo para distinguir entre las dos clases, con un poder predictivo considerable.

Además, se calculó el intervalo de confianza (IC) del 95% para el AUC, el cual se ubicó entre 0.8349 y 0.9261 según el método de DeLong. Este intervalo de confianza valida la precisión del modelo, demostrando que el rendimiento estimado del modelo es confiable y se encuentra dentro de un rango adecuado para su aplicación en la predicción de la clase 'CON.BCIAO'.

Métrica	RN Óptima	SVM
Accuracy	0.8415	0.8252
95% CI	(0.7897, 0.8848)	(0.7719, 0.8705)
Kappa	0.6829	0.6504
McNemar's Test P-Value	0.5218	0.2225
Sensitivity	0.8618	0.8618
Specificity	0.8211	0.7886
Pos Pred Value (PPV)	0.8281	0.8030
Neg Pred Value (NPV)	0.8559	0.8509
Prevalence	0.5000	0.5000
Detection Rate	0.4309	0.4309
Detection Prevalence	0.5203	0.5366
Balanced Accuracy	0.8415	0.8252

F1 Score	0.8446	0.8313
----------	--------	--------

Tabla 8 : Comparación de métricas en los diferentes modelos (RN y SV). *Elaboración propia*

Al comparar los modelos de Red Neuronal (RN) y Support Vector Machine (SVM) utilizando métricas de rendimiento, la red neuronal muestra un desempeño ligeramente superior en varias áreas clave. La accuracy de la RN es 0.8415, superior a la de SVM (0.8252), lo que indica que la RN tiene una tasa de clasificación correcta más alta. La sensibilidad de la RN (0.8618) es igual a la del SVM (0.8618), lo que significa que ambos modelos tienen la misma capacidad para identificar correctamente los casos positivos de "CON:BCIAO". Sin embargo, la especificidad de la RN es superior, lo que refleja una mayor capacidad para identificar correctamente los casos negativos de "SIN:BCIAO". Por otro lado, el Kappa de la RN (0.6829) es más alto que el del SVM (0.6504), lo que refleja una mayor concordancia entre las predicciones y las verdaderas clases en la RN.

En cuanto a otras métricas, el valor predictivo positivo (PPV) y el valor predictivo negativo (NPV) son también ligeramente más altos en la RN, indicando que tiene una mejor precisión en la predicción tanto de positivos como de negativos. La balanced accuracy, que promedia sensibilidad y especificidad, también es ligeramente superior en la RN (0.8415 frente a 0.8252).

El F1 score, que balancea la precisión y la sensibilidad, es también superior en la RN (0.8446 vs 0.8313), lo que sugiere que la RN maneja mejor el equilibrio entre la predicción de ambas clases. En resumen, aunque ambos modelos tienen un rendimiento competitivo, la RN muestra una ligera ventaja general en precisión, especificidad y métricas balanceadas.

INTRAOPERATORIO

RED NEURONAL

En este análisis de datos en R, se particionó el conjunto de datos en una proporción de 70% para entrenamiento y 30% para el testeo, utilizando una semilla de 27848992 para garantizar la reproducibilidad. Tras verificar que no existen valores nulos en el conjunto de entrenamiento, se convirtió la variable de respuesta DIFF a un formato numérico adecuado. El conjunto de entrenamiento resultante contiene 848 observaciones, mientras que el de prueba tiene 362. Ambas particiones mantienen una distribución representativa de las clases en DIFF, con una proporción balanceada entre los conjuntos, lo que asegura que el modelo sea entrenado y evaluado con una muestra de datos representativa.

A continuación, se compararon los estadísticos de la variable DIFF entre el conjunto de datos original, el conjunto de entrenamiento y el conjunto de prueba, con el objetivo de verificar que la partición no alterara significativamente su distribución. A continuación se presenta una tabla con estas comparaciones:

Estadísticos de DIFF en Datos, Entrenamiento y Testeo		
Conjunto	Media	Mediana Rango
Datos	37.25455	35 10 - 140
Entrenamiento	37.28184	35 10 - 140
Testeo	37.19061	35 10 - 105

Los resultados muestran que la media, la mediana y el rango de DIFF son muy similares en los tres conjuntos, lo que indica que la partición ha mantenido una distribución representativa de los datos originales.

Entrenamiento del modelo

En esta parte, se utilizó un bucle para entrenar el modelo de red neuronal con diferentes combinaciones de hiperparámetros. Los valores de los hiperparámetros size (tamaño de la red) y decay (decadencia del aprendizaje) fueron definidos en una cuadrícula con los siguientes valores posibles: size = c(1, 3, 5) y decay = c(0, 0.01, 0.1). Para cada combinación, se entrenó un modelo de red neuronal utilizando la función train de caret, con validación cruzada de 5 pliegues (5-fold cross-validation). Durante este proceso, se utilizó el escalado de los datos y se limitó el número de iteraciones a 300. El objetivo era encontrar los hiperparámetros que minimicen el error en el conjunto de prueba.




Figura 40 : Gráfico de importancia de cada variable y rendimiento del modelo que muestra el accuracy alcanzado por cada combinación de hiperparámetros probada. Elaboración propia.

Rendimiento del modelo

El rendimiento del modelo se evaluó utilizando tres métricas: RMSE (Root Mean Squared Error), MAE (Mean Absolute Error) y R^2 . Durante el bucle, para cada conjunto de hiperparámetros, el modelo entrenado hizo predicciones sobre el conjunto de prueba. Luego, se calcularon los valores de RMSE, MAE y R^2 . El modelo con las mejores métricas fue seleccionado como el modelo final, y los hiperparámetros asociados con este modelo fueron registrados. Los resultados finales mostraron que el modelo con los hiperparámetros size = 3 y decay = 0 alcanzó un RMSE de 15.60395, un MAE de 12.3638

y un $R^2 = 0.2730663$, lo que indicó que este modelo fue el más preciso en cuanto a las métricas de error.




Figura 41 : Diagrama de dispersión que compara las predicciones realizadas por el modelo con los valores reales de la variable DIFF en el conjunto de prueba. Elaboración propia.

Al observar el gráfico, se nota que los puntos no se encuentran alineados en torno a la línea roja. Esto indica que existe una discrepancia entre las predicciones y los valores reales, lo que refleja la presencia de errores en el modelo. La dispersión de los puntos alrededor de la línea roja muestra la magnitud de estos errores: los puntos más cercanos a la línea representan predicciones más precisas, mientras que los puntos más alejados reflejan mayores errores.

Además, se puede observar que, aunque hay una tendencia general que sigue una dirección positiva (es decir, a medida que aumentan los valores reales también aumentan las predicciones), el modelo parece no capturar la variabilidad de los datos reales. Por ejemplo, hay concentraciones notables de puntos en ciertos valores específicos del eje vertical (predicciones), lo que podría sugerir que el modelo tiende a predecir ciertos valores con mayor frecuencia, posiblemente debido a limitaciones en su capacidad para ajustarse a la complejidad de los datos.

Este gráfico sugiere que el modelo tiene una relación aproximada con los valores reales, pero no logra un ajuste completamente preciso.



Figura 42 : Diagrama de distribución de residuos del modelo.
Elaboración propia.

El histograma presentado muestra la distribución de los residuos, definidos como la diferencia entre los valores reales y las predicciones del modelo. En el eje horizontal se representan los valores de los residuos, mientras que en el eje vertical se indica la frecuencia, es decir, la cantidad de casos correspondientes a cada intervalo de residuos. Un residuo cercano a cero indica que la predicción del modelo fue precisa, mientras que los valores positivos representan subestimaciones del modelo y los valores negativos, sobreestimaciones.

La distribución tiene una forma aproximadamente simétrica y está centrada alrededor de cero, lo que es un buen indicador de que los errores del modelo no están sesgados hacia sobreestimaciones o subestimaciones sistemáticas. Esto sugiere que el modelo realiza predicciones de manera equilibrada en términos generales. Sin embargo, se observa la presencia de residuos más grandes en las colas del histograma, tanto a la izquierda como a la derecha, lo que sugiere la existencia de valores atípicos o casos en los que el modelo cometió errores significativos.

El rango de los residuos abarca aproximadamente desde -50 hasta 50, lo que indica que, en algunos casos, las predicciones del modelo difieren considerablemente de los valores reales. A pesar de ello, la mayoría de los residuos están concentrados cerca de cero, lo que sugiere que el modelo tiene un buen desempeño promedio.

En resumen, el gráfico muestra que el modelo predice los valores reales con una buena precisión en la mayoría de los casos, pero también presenta algunas limitaciones para manejar casos extremos o atípicos, que se reflejan en las colas de la distribución.

SUPPORT VECTOR MACHINE (SVM)

Se desarrollo de un modelo de Support Vector Machines (SVM) con núcleo radial para predecir la variable DIFF. Se inicia con el particionamiento de los datos en conjuntos de entrenamiento (70%) y testeo (30%), manteniendo la misma semilla (27848992) que la utilizada en la RN previa. Las variables categóricas se transforman en formato numérico para su compatibilidad con el modelo. Posteriormente, se define una configuración de validación cruzada (5-fold cross-validation) para garantizar la evaluación del modelo durante el ajuste de hiperparámetros.

Entrenamiento del modelo

El modelo SVM se entrenó utilizando un núcleo radial (Radial Basis Function Kernel), aplicando escalado y centrado a las variables predictoras. Para garantizar un ajuste óptimo, se utilizó validación cruzada de 5 particiones (5-fold cross-validation) y una cuadrícula de hiperparámetros que combina valores de C (cost) y sigma.

848 samples
7 predictor

Pre-processing: centered (7), scaled (7)
Resampling: Cross-Validated (5 fold)
Summary of sample sizes: 678, 678, 678, 680, 678
Resampling results across tuning parameters:

C	sigma	RMSE	Rsquared	MAE
0.1	0.01	14.30260	0.5111091	9.705247
0.1	0.10	13.52598	0.5238242	8.882667
0.1	1.00	15.60283	0.3852940	10.154287
1.0	0.01	12.88452	0.5400871	8.713489
1.0	0.10	12.15493	0.5921682	8.141062
1.0	1.00	12.74735	0.5515466	8.200400
10.0	0.01	12.33263	0.5785716	8.323586
10.0	0.10	12.48643	0.5730364	8.076465
10.0	1.00	12.36040	0.5788600	8.378638
100.0	0.01	12.05290	0.5959383	8.070422
100.0	0.10	13.62228	0.5332160	8.452514
100.0	1.00	13.71773	0.5162026	9.115879

RMSE was used to select the optimal model using the smallest value.
The final values used for the model were sigma = 0.01 and C = 100.




Figura 43 : Gráfico de rendimiento del modelo que muestra el accuracy alcanzado por cada combinación de hiperparámetros probada. Elaboración propia.

El proceso identificó los valores óptimos para minimizar el error cuadrático medio (RMSE): $C = 100$ y $\sigma = 0.01$.




Figura 44 : Gráfico de importancia de cada variable. Elaboración propia.

Rendimiento del modelo

El modelo entrenado se evaluó sobre el conjunto de prueba, generando predicciones para la variable "DIFF". Las métricas de desempeño obtenidas fueron:

R^2 : 0.5583
RMSE: 12.0161
MAE: 8.2238

Se puede observar que las métricas resultantes mejoran con respecto al mismo modelo donde se usó RN. Probablemente SVM sea más robusta frente a outliers debido a su enfoque en los vectores de soporte, que representan los datos más cercanos al margen y son los únicos que influyen en el ajuste del modelo.




Figura 45 : Diagrama de dispersión que compara las predicciones realizadas por el modelo con los valores reales de la variable DIFF en el conjunto de prueba. Elaboración propia

El gráfico muestra la comparación entre los valores reales de la variable DIFF y las predicciones generadas por el modelo SVM con kernel radial en un conjunto de prueba.

Se observa que el modelo tiene un desempeño razonable, ya que muchos puntos están distribuidos alrededor de la línea de referencia. Sin embargo, se puede notar cierta dispersión, especialmente en los valores altos, donde las predicciones tienden a subestimar los valores reales, y en los valores bajos, donde la sobreestimación es más común. Esto sugiere que el modelo tiene dificultades para capturar con precisión los extremos de la variable DIFF, aunque logra un ajuste relativamente adecuado en la mayoría de los casos.




Figura 46 : Diagrama de distribución de residuos del modelo. Elaboración propia.

Los residuos representan la diferencia entre los valores reales y las predicciones del modelo. En este gráfico, la mayor parte de los residuos se concentra en torno a cero, lo que indica que el modelo ha logrado un buen ajuste para la mayoría de las observaciones, con errores pequeños y relativamente balanceados.

Sin embargo, se observan algunos residuos positivos y negativos alejados del centro, lo que sugiere la presencia de ciertos errores extremos. En particular, hay una cola en el extremo derecho que indica predicciones que subestimaron los valores reales en gran medida. Este tipo de dispersión en los residuos podría señalar limitaciones en la capacidad del modelo para manejar variabilidad extrema o atípicos en la variable DIFF. La asimetría y la presencia de estos valores atípicos indican que los supuestos de homocedasticidad y normalidad de los residuos podrían no cumplirse por completo.

Para resolver esta cuestión se identifican los outliers de la variable DIFF (n=44) y se eliminan, con este nuevo subset se entrena y valida el modelo con RN y SVM.

```
> print(df_outliers_count)
Variable Cantidad_Outliers
EDAD          EDAD          28
T.CLAMP       T.CLAMP       10
T.BOMB        T.BOMB        15
DIFF          DIFF          44
```

Se compararon los estadísticos de la variable DIFF entre el conjunto de datos original, el conjunto de entrenamiento y el conjunto de testeo, con el objetivo de verificar que la partición no alterará significativamente su distribución posterior a la eliminación de outliers.

Estadísticos de DIFF en Datos, Entrenamiento y Testeo		
Conjunto	Media	Mediana Rango
Datos	35.23413	33 10 - 75
Entrenamiento	35.23413	33 10 - 75
Testeo	35.23413	33 10 - 75

RN (SIN OUTLIERS)

Entrenamiento del modelo

En este procedimiento, los datos se particionaron en un 70% para entrenamiento y un 30% para prueba, asegurando una distribución representativa de la variable DIFF en ambos conjuntos mediante la función createDataPartition. Además, se empleó validación cruzada de 5 folds para entrenar redes neuronales ajustando hiperparámetros clave (size y decay) y se limitó el número de interacciones a 300. Se utilizó el mismo bucle (loop) que en el modelo de RN previo.




Figura 47 : Gráfico de importancia de cada variable y rendimiento del modelo que muestra el accuracy alcanzado por cada combinación de hiperparámetros probada. Elaboración propia.

Rendimiento del modelo

Los resultados finales mostraron que el modelo con los hiperparámetros $\text{size} = 3$ y $\text{decay} = 0.1$ alcanzó un RMSE de 13.31654, un MAE de 10.52438 y un $R^2 = 0.2438234$, lo que indicó que este modelo fue el más preciso en cuanto a las métricas de error.




Figura 48 : Diagrama de dispersión que compara las predicciones realizadas por el modelo con los valores reales de la variable DIFF en el conjunto de prueba y diagrama de distribución de residuos del modelo. Elaboración propia

Se observa cierta dispersión alrededor de la línea, lo que indica que, si bien el modelo captura algunas tendencias generales, presenta errores en la predicción. En lo que respecta al histograma de residuos presenta una distribución aproximadamente simétrica centrada en cero. Esto sugiere que los errores no presentan sesgo significativo, aunque algunos valores extremos podrían afectar el rendimiento predictivo.

SVM (SIN OUTLIERS)

Se desarrollo de un modelo de Support Vector Machines (SVM) con núcleo radial para predecir la variable DIFF. Se particionó los datos en conjuntos de entrenamiento (70%) y testeo (30%), manteniendo la misma semilla (27848992) que la utilizada.

Entrenamiento del modelo

Las variables categóricas se transforman en formato numérico para su compatibilidad con el modelo. Posteriormente, se define una configuración de validación cruzada (5-fold cross-validation) para garantizar la evaluación del modelo durante el ajuste de hiperparámetros.

819 samples
7 predictor

Pre-processing: centered (7), scaled (7)
Resampling: Cross-Validated (5 fold)
Summary of sample sizes: 655, 655, 655, 656, 655
Resampling results across tuning parameters:

C	sigma	RMSE	Rsquared	MAE
0.1	0.01	11.606062	0.5249379	8.556127
0.1	0.10	10.882973	0.5377311	7.888197
0.1	1.00	12.172449	0.4455909	8.907964
1.0	0.01	10.560554	0.5403939	7.611795
1.0	0.10	9.969375	0.5895312	7.301095
1.0	1.00	10.139446	0.5746231	7.343691
10.0	0.01	10.415874	0.5524258	7.516594
10.0	0.10	10.096894	0.5860078	7.166116
10.0	1.00	10.474320	0.5542010	7.476430
100.0	0.01	10.390499	0.5603654	7.478297
100.0	0.10	10.838345	0.5486980	7.530654
100.0	1.00	11.463221	0.4912311	7.973560

RMSE was used to select the optimal model using the smallest value.
The final values used for the model were sigma = 0.1 and C = 1.




Figura 49 : Gráfico de importancia de cada variable y rendimiento del modelo que muestra el accuracy alcanzado por cada combinación de hiperparámetros probada. Elaboración propia.

El proceso identificó los valores óptimos para minimizar el error cuadrático medio (RMSE): $C = 1$ y $\sigma = 0.1$.

Rendimiento del modelo

El modelo entrenado se evaluó sobre el conjunto de prueba, generando predicciones para la variable 'DIFF'. Las métricas de desempeño obtenidas fueron:

R^2 : 0.5917
RMSE: 9.7782
MAE: 6.9633





Figura 50 : Diagrama de dispersión que compara las predicciones realizadas por el modelo con los valores reales de la variable DIFF en el conjunto de prueba y diagrama de distribución de residuos del modelo. Elaboración propia

En este caso, se observa una mejor alineación de los puntos a lo largo de la línea de referencia en comparación con los gráficos anteriores, lo que sugiere que el modelo

tiene un rendimiento más sólido en las predicciones. Sin embargo, aún persiste cierta dispersión, especialmente en valores altos de DIFF.

En cuanto a la distribución de los residuos es aproximadamente simétrica y centrada en cero, lo que es una indicación favorable de que los errores están distribuidos de manera uniforme sin un sesgo evidente. No obstante, se detectan valores extremos que podrían estar influyendo en el rendimiento general del modelo. Este análisis sugiere que, si bien el modelo ha mejorado, la dispersión de los datos genera nuevos outliers a pesar de haber quitado los más representativos.

Métrica	CON OUTLIERS		SIN OUTLIERS	
	RN	SVM	RN	SVM
R^2	0.2730663	0.5583	0.2438234	0.5917
RMSE	15.60395	12.0161	13.31654	9.7782
MAE	12.3638	8.2238	10.52438	6.9633

Tabla 9: Tabla comparativa de métricas de ambos modelos (RN y SVM) con y sin outliers. Elaboración propia

La tabla comparativa muestra las métricas de evaluación del mismo modelo predictivo con RN y SVM, evaluados bajo dos escenarios: incluyendo outliers y excluyéndolos.

- Con outliers

El modelo SVM supera al modelo RN en las tres métricas, con un R^2 más alto (0.5583 vs. 0.2730663), menor RMSE (12.0161 vs. 15.60395) y menor MAE (8.2238 vs. 12.3638). Esto sugiere que SVM maneja mejor la presencia de valores atípicos.

- Sin outliers

Ambos modelos mejoran en rendimiento al eliminar los outliers, como lo indican los menores valores de RMSE y MAE.

SVM sigue siendo el modelo superior, con un R^2 de 0.5917 vs 0.2438234 para RN, un RMSE de 9.7782 vs 13.31654, y un MAE de 6.9633 vs 10.52438.

El modelo SVM muestra un desempeño consistentemente superior al modelo RN, tanto CON cómo SIN outliers. Además, la exclusión de outliers mejora significativamente el rendimiento de ambos modelos, aunque SVM parece ser más robusto ante la presencia de valores atípicos.

PREDICCIÓN DE UN CASO

Paciente **masculino** de **70 años** de edad presentó cuadro clínico caracterizado por ángor clase funcional III el día 17/10 por lo que decidió consultar hospital zonal. En dicho centro se realizó electrocardiograma que evidenció ritmo sinusal sin signos de injuria subepicárdica aguda onda T negativa en cara anterior. Se dosaron troponinas que fueron positivas. Se interpretó cuadro como infarto agudo de miocardio tipo T anterior por lo que se decidió derivación al centro de mayor complejidad.

A su ingreso el día 19/10 paciente hemodinámicamente estable asintomático para ángor palpitations y sin signos de bajo gasto cardiaco o sobrecarga hídrica se realizó electrocardiograma que evidenció ritmo sinusal sin signos de injuria subepicárdica aguda con onda T negativa en cara anterior y se dosaron biomarcadores TN los cuales fueron positivos (4451/2963 pg/dl) se interpretó cuadro como infarto agudo de miocardio tipo T anterior por lo que se decidió su internación en unidad coronaria para monitoreo y tratamiento.

El día 21/10 se realizó cinecoronariografía por abordaje radial derecho con evidencia de tronco de coronaria izquierda 90 % ostial. Descendente anterior 90 % proximal 1º latero ventricular 90 % proximal, coronaria derecha 60 % proximal, descendente posterior 90 % proximal, el procedimiento fue bien tolerado sin complicaciones.

Se realizó ecocardiograma transtorácico con evidencia de fracción de eyección del 40 % hipoquinesia anterior, septal apical, inferoapical, septo apical y estenosis aórtica moderada con insuficiencia tricúspide leve.

En contexto de diagnóstico de enfermedad de tronco de la coronaria izquierda y tres vasos asociados a estenosis aórtica moderada fue valorado por el servicio de cirugía cardiovascular decidiéndose resolución quirúrgica combinada.

El día 1/11 se realizó cirugía de revascularización miocárdica con puente arterial mamario a arteria descendente anterior, puente venoso a latero ventricular de circunfleja y reemplazo aórtico biológico Dafoil Nº 21. No se realizó puente a coronaria derecha por lechos distales deficientes. Tiempo clampeo 150 min. tiempo de bomba extracorpórea 190 min. Durante la cirugía, dada la dificultad para salida de CEC se colocó BCIAO.

Se colocaron tres tubos de drenaje uno mediastinal, uno pleural derecho y otro pleural izquierdo. Se colocó marcapasos epicárdico al ventrículo derecho se completó protocolo hemostático con ácido tranexámico. Requirió intraquirófano 2 U glóbulos rojos y un Pool de plaquetas.

Ingresa a recuperación cardiovascular, día 2/11 se realizó retiro de BCIAO, el día 3/11 se realizó retiro de tubos de drenaje. evolucionó con FAARV que requirió cardioversión farmacológica. Buena evolución posterior alta sanatorial día 9/11

cálculo de DIFF: 190-150= 40 minutos

PREOPERATORIO				
CLASIFICACIÓN	RN		SVM	
BCIAO	CON	SIN	CON	SIN
PROBABILIDAD	0.9113694	0.08863057	0.912929	0.08707

INTRAOPERATORIO				
PREDICCIÓN	RN		SVM	
OUTLIERS	CON	SIN	CON	SIN
DIFF (min)	35.60677	47.35166	52.88792	57.91231

Tabla 10: Tabla comparativa de clasificación (preoperatorio) y predicción (intraoperatorio) con ambos métodos (RN y SVM. Elaboración propia

- Clasificación Preoperatoria
Los modelos RN y SVM coinciden en clasificar al paciente como necesitando BCIAO, con alta probabilidad.
- Predicción de DIFF
SVM estima tiempos ligeramente mayores que RN, tanto con como sin outliers. La presencia de outliers influye significativamente en los resultados del modelo RN, pero menos en SVM, lo que puede indicar mayor robustez de SVM frente a valores extremos.

Estos resultados refuerzan la utilidad de ambos modelos para casos clínicos, destacando la alta probabilidad preoperatoria de necesidad de BCIAO y estimaciones intraoperatorias del tiempo DIFF que podrían guiar decisiones quirúrgicas.

DISCUSIÓN

El presente trabajo aborda dos objetivos principales relacionados con la cirugía cardíaca con circulación extracorpórea (CEC). En primer lugar, se desarrolló un modelo de clasificación preoperatorio para identificar pacientes con una mayor probabilidad de requerir un balón de contrapulsación intraaórtico (BCIAO). En segundo lugar, se diseñó un modelo predictivo para estimar la variable DIFF, que representa la diferencia entre el tiempo total de bomba y el tiempo de clampeo aórtico, como indicador intraoperatorio del estado hemodinámico del paciente. Estos dos enfoques son complementarios y reflejan una aproximación integral que combina predicción preoperatoria con evaluación intraoperatoria.

La identificación temprana de la necesidad de BCIAO representa un avance significativo frente a las limitaciones de las escalas de riesgo globales actuales, como el EUROSCORE II y el STS. Estas escalas, aunque ampliamente utilizadas, carecen de especificidad para el periodo preoperatorio y no ofrecen recomendaciones claras sobre intervenciones intraoperatorias. El modelo de clasificación desarrollado en este estudio utiliza variables demográficas (edad, sexo), quirúrgicas (tipo de cirugía, posición de válvula) y clínicas (hipotermia, fracción de eyección del ventrículo izquierdo [FEY]), ofreciendo una predicción más precisa y personalizada. Esto es especialmente relevante considerando que decisiones como la colocación del BCIAO suelen depender de la experiencia clínica del cirujano, a menudo tomada bajo presión durante la cirugía.

Los modelos generados muestran que la importancia de cada variable a la hora de clasificar al paciente en cuanto si requerirá de BCIAO o no, se puede observar que si bien la FEY, que ha sido utilizada hasta ahora como único pilar cuando se piensa en la necesidad de soporte circulatorio, juega un rol esencial parece no ser la única variable a considerar.

En cuanto al método utilizado para clasificar previo a la cirugía si el paciente requerirá soporte circulatorio (BCIAO) la RN ofrece mejores métricas que el SVM para el mismo modelo.

Por otro lado, la variable DIFF constituye un indicador innovador del estado intraoperatorio del paciente, capturando aspectos clave de la dificultad en la salida de la bomba extracorpórea. Los resultados demuestran que DIFF es un reflejo directo de la complejidad hemodinámica del caso quirúrgico, correlacionándose significativamente con variables como FEY y tipo de cirugía. Poder predecir esta variable nos ayuda a tener una idea de la dificultad en la salida de CEC, de cuanto se puede complejizar que el corazón recientemente operado pueda hacerse cargo del gasto cardiaco del paciente y es lógico suponer que a mayores valores de DIFF mayor será la probabilidad de requerir un soporte circulatorio (BCIAO). Esto ha sido demostrado en el presente trabajo.

En cuanto a la predicción de DIFF se lograron mejores métricas con el método de SVM que con RN, aunque moderadas ($R^2 = 0.5917$, RMSE = 9.7782 y MAE= 6.9633).

En términos metodológicos, el uso de técnicas de aprendizaje automático, como redes neuronales y máquinas de soporte vectorial (SVM), permitió abordar relaciones no lineales y complejas entre las variables. Estas técnicas demostraron ser efectivas tanto en la clasificación como en la predicción, alcanzando altos niveles de precisión, sensibilidad y especificidad en la identificación de la necesidad de BCIAO en la clasificación y un moderado R^2 , RMSE y MAE en la estimación de DIFF. Sin embargo, el tamaño limitado de la base de datos ($n = 1210$), junto con la ausencia de variables complementarias como marcadores inflamatorios o patologías preexistentes, restringe la capacidad de generalización de los modelos.

Los resultados obtenidos en el análisis bivariado también proporcionan información valiosa. Por ejemplo, se observó que variables como el tipo de cirugía y la posición de la válvula tienen una influencia significativa en la necesidad de BCIAO, mientras que DIFF muestra asociaciones importantes con FEY y débiles con la edad. Este análisis confirma la relevancia de las variables seleccionadas en los modelos predictivos y respalda la hipótesis inicial de que factores clínicos y quirúrgicos específicos son determinantes clave en la planificación y ejecución de cirugías cardíacas con CEC.

Una consideración importante es la aplicabilidad clínica de estos modelos. Aunque los resultados son prometedores, la implementación en la práctica real requerirá validación prospectiva y la integración con sistemas hospitalarios. Además, la naturaleza retrospectiva del estudio implica que los modelos están optimizados para el conjunto de datos analizado, lo que puede limitar su desempeño en otras poblaciones.

Este trabajo demuestra el potencial de las herramientas de aprendizaje automático para transformar la toma de decisiones en cirugía cardíaca. Al proporcionar modelos predictivos personalizados, se sientan las bases para una medicina más precisa y adaptada a las características individuales del paciente.

CONCLUSIÓN

El presente estudio cumple adecuadamente los objetivos propuestos de desarrollar un modelo de clasificación preoperatorio para identificar la necesidad de BCIAO y un modelo predictivo para estimar la variable DIFF. Estos enfoques representan una contribución significativa al campo de la cirugía cardíaca con CEC, abordando limitaciones clave de las herramientas actuales y proponiendo soluciones personalizadas basadas en datos clínicos.

En primer lugar, el modelo de clasificación demuestra que es posible anticipar con precisión la necesidad de soporte hemodinámico adicional mediante la integración de variables preoperatorias. Esto permite una planificación quirúrgica más informada, optimizando la colocación del BCIAO y reduciendo la incertidumbre intraoperatoria. La capacidad del modelo para superar las deficiencias de los puntajes de riesgo globales actuales subraya su relevancia clínica, especialmente en cirugías de alta complejidad.

Por otro lado, la variable DIFF emerge como un indicador intraoperatorio clave, reflejando la dificultad hemodinámica asociada con el procedimiento quirúrgico. Aunque su uso está limitado al análisis retrospectivo, DIFF ofrece una valiosa perspectiva sobre los factores que influyen en la recuperación hemodinámica del paciente, como FEY y tiempo de clampeo. Esto no solo valida la utilidad de DIFF como métrica clínica, sino que también abre la puerta a estrategias quirúrgicas y postoperatorias más personalizadas.

El uso de técnicas de aprendizaje automático, como redes neuronales y SVM, marca un avance importante en la modelización de problemas complejos en cirugía cardíaca. Estos métodos permitieron desarrollar modelos robustos que no solo alcanzan altos niveles de precisión, sino que también abordan relaciones no lineales entre las variables. Sin embargo, el tamaño limitado del conjunto de datos y la ausencia de variables complementarias representan limitaciones significativas que deben abordarse en futuros estudios.

Además, los resultados obtenidos destacan la importancia de una medicina personalizada y basada en datos, donde las decisiones no se limitan a la intuición clínica, sino que están respaldadas por modelos matemáticos y estadísticos. Esto tiene el potencial de mejorar los resultados quirúrgicos, reducir la morbilidad y optimizar el uso de recursos en el entorno hospitalario.

En síntesis, el desarrollo de estos modelos representa un paso hacia una cirugía cardíaca más precisa y adaptada a las necesidades individuales de los pacientes. A pesar de las limitaciones, los hallazgos proporcionan una base sólida para futuras investigaciones y aplicaciones clínicas, consolidando el papel de las herramientas de aprendizaje automático en la toma de decisiones médicas.

TRABAJO FUTURO

El trabajo futuro debe enfocarse en tres áreas principales para fortalecer y expandir los hallazgos del presente estudio.

- **Ampliación y Diversificación de la Base de Datos** Es fundamental recolectar datos de una población más amplia y diversa, incluyendo pacientes de diferentes regiones geográficas y perfiles clínicos. Esto mejorará la capacidad de generalización de los modelos y permitirá identificar patrones más robustos.
- **Integración de Variables Complementarias** La incorporación de parámetros adicionales, como marcadores inflamatorios, comorbilidades y datos laboratoriales, podría aumentar la precisión del modelo y proporcionar una visión más completa del estado clínico del paciente.
- **Validación Prospectiva y Aplicación Clínica** Se deben realizar estudios prospectivos para validar los modelos en escenarios clínicos reales. Esto permitirá evaluar su desempeño en tiempo real y determinar su impacto en la planificación quirúrgica y los resultados postoperatorios.
- **Desarrollo de Herramientas Digitales** La creación de aplicaciones o plataformas integradas que utilicen estos modelos predictivos facilitaría su implementación en hospitales, mejorando la toma de decisiones en tiempo real.
- **Exploración de Nuevas Técnicas** Métodos avanzados como redes neuronales profundas o modelos de aprendizaje por refuerzo podrían optimizar aún más las predicciones, capturando relaciones más complejas entre las variables.

En conjunto, estos esfuerzos contribuirán a consolidar el uso de modelos predictivos en la práctica clínica, mejorando los resultados de los pacientes y avanzando hacia una medicina más precisa y personalizada.

REFERENCIAS

Alwan, M. (2019). Heart failure management: Tools and therapies. *Cardiovascular Innovations and Applications*, 4(3), 67-89.

Baufreton, C., Corbeau, J. J., & Pinaud, F. (2006). Réponse inflammatoire et perturbations hématologiques en chirurgie cardiaque: Vers une circulation extracorporelle plus physiologique. *Annales Françaises d'Anesthésie et de Réanimation*, 25(5), 510-520. <https://doi.org/10.1016/j.annfar.2005.12.002>

Cardiogenic Shock and Intra-aortic Balloon Pump by Dr. Cal Shipley, M.D. Animación. [URL: <https://carloslugones07.github.io/TFI/video.html>]

Elahi, M. M., Khan, J. S., & Matata, B. M. (2006). Deleterious effects of cardiopulmonary bypass in coronary artery surgery and scientific interpretation of off-pump's logic. *Acute Cardiac Care*, 8(4), 196-209. <https://doi.org/10.1080/17482940600981730>

Esper, S. A., Subramaniam, K., & Tanaka, K. A. (2014). Pathophysiology of cardiopulmonary bypass: Current strategies for the prevention and treatment of anemia, coagulopathy, and organ dysfunction. *Seminars in Cardiothoracic and Vascular Anesthesia*, 18(2), 161-176. <https://doi.org/10.1177/1089253214532375>

Home euroscore scoring calculator references. Interactive calculator. [URL: <http://51.178.225.9/calc.html>]

Kirklin, J. W., & Barratt-Boyes, B. G. (2012). *Kirklin/Barratt-Boyes cardiac surgery* (4th ed.). Elsevier Health.

Levy, J. H., & Tanaka, K. A. (2003). Inflammatory response to cardiopulmonary bypass. *The Annals of Thoracic Surgery*, 75(6), S715-S720. [https://doi.org/10.1016/s0003-4975\(02\)04701-x](https://doi.org/10.1016/s0003-4975(02)04701-x)

Mehta, R. H., & O'Shea, J. C. (2014). Percutaneous mechanical circulatory support for patients in cardiogenic shock. *Circulation*, 121(21), 2718-2729. <https://doi.org/10.1007/s11936-015-0426-6>

Murphy, G. J., & Angelini, G. D. (2004). Side effects of cardiopulmonary bypass: What is the reality?. *Journal of Cardiothoracic and Vascular Anesthesia*, 18(4), 482-492. <https://doi.org/10.1111/j.0886-0440.2004.04101.x>

Thiele, H., Zeymer, U., Neumann, F. J., & Desch, S. (2013). Intra-aortic balloon support for myocardial infarction with cardiogenic shock. *The New England Journal of Medicine*, 367(14), 1287-1296. <https://doi.org/10.1056/NEJMoa1208410>

The Society of Thoracic Surgeons. (n.d.). STS short-term / operative risk calculator. Adult cardiac surgery database – All procedures.
[URL: <https://acsdriskcalc.research.sts.org/>]

Warden HE, Cohen M, Read RC, Lillehei CW (1955). Controlled cross circulation for direct-vision intracardiac surgery: correction of ventricular septal defects, atrioventricularis communis, and tetralogy of Fallot, *Post Grad Med* [Minneapolis] 17:288-396

Zalaquett, R. (2022). Desarrollo histórico de la cirugía cardiovascular. *Revista Médica Clínica Las Condes*, 33(3), 192-200. <https://doi.org/10.1016/j.rmcl.2022.03.017>